



**POLSKO-JAPOŃSKA AKADEMIA
TECHNIK KOMPUTEROWYCH**

Wydział Informatyki

Katedra Systemy Inteligentne i Data Science
Specjalizacja Inteligentne Systemy Przetwarzania Danych

Lena Marusik

25273

Prognozowanie Cen Zamknięcia Bitcoin i Ethereum

Praca Inżynierska

Promotor dr hab. Grzegorz Wójcik,
prof. PJATK

Warszawa, styczeń, 2025 rok

Spis treści

1	Streszczenie	6
1.1	Streszczenie	6
1.2	Słowa Kluczowe	6
2	Wykaz skrótów	6
3	Wstęp	7
3.1	Wprowadzenie do Tematu	7
3.2	Problem Badawczy	7
3.3	Cele Pracy	7
3.4	Motywacja	8
3.5	Zakres Pracy	8
3.6	Ryzyka Projektowe	8
4	Metodyka pracy	9
4.1	Charakterystyka Źródła Danych	9
4.2	Przetwarzanie Danych	9
4.3	Metody Badawcze	9
4.4	Metryki i Kryteria Ewaluacji	10
4.5	Narzędzia i Technologie	10
4.6	Plan Działania	11
5	Przegląd literatury	11
5.1	Historyczny Kontekst Prognozowania Cen Kryptowalut	11
5.2	Podejścia Oparte na Uczeniu Maszynowym w Prognozowaniu Cen Kryptowalut	11
5.3	Analiza i Wybór Modeli Predykcyjnych	12
5.4	Metryki Ewaluacji Modeli Predykcyjnych	16
5.5	Podsumowanie Przeglądu Literatury	18
6	Zbiór Danych	18
7	Instalacja i Import Bibliotek	20
7.1	Instalacja Bibliotek	20
7.2	Import Bibliotek	20
8	Pobieranie i Wstępne Przetwarzanie Danych	22
8.1	Pobieranie Danych	22
8.2	Wstępne Przetwarzanie Danych	22
8.3	Przygotowanie Danych do Użycia w Modelu	22
8.3.1	Skalowanie Danych	22
8.3.2	Generowanie Szeregów Czasowych	23
9	Eksploracyjna Analiza Danych (EDA)	24
9.1	Inspekcja Danych	24
9.2	Analiza Wizualna Danych Historycznych	25
9.2.1	Histogram Cen Zamknięcia dla BTC i ETH	25
9.2.2	Wykres Pudełkowy Cen Zamknięcia dla BTC i ETH	27

9.2.3	Wykres Liniowy Ceny Zamknięcia w Czasie dla BTC i ETH	29
9.2.4	Wykres 30 Dniowej Średniej Kroczącej Cen Zamknięcia dla BTC i ETH	31
9.2.5	Wykres Liniowy Zmian Procentowych Cen Zamknięcia dla BTC i ETH	33
9.2.6	Wykres Gęstości Cen Zamknięcia dla BTC i ETH	35
9.2.7	Mapa Korelacji Zmiennych Rynkowych dla BTC i ETH	37
9.2.8	Wykres Autokorelacji dla BTC i ETH	40
9.2.9	Wykres Trendu Czasowego Cen Zamknięcia dla BTC i ETH	43
9.2.10	Wykres Reszt dla BTC i ETH	45
10	Budowa i Trening Modeli	47
10.1	Budowa i Trening Modeli LSTM dla BTC i ETH	47
10.2	Budowa i Trening Modeli RNN dla BTC i ETH	49
10.3	Budowa i Trening Modeli GRU dla BTC i ETH	51
10.4	Budowa i Trening Modeli CNN dla BTC i ETH	53
10.5	Budowa i Trening Modeli LightGBM dla BTC i ETH	55
10.6	Budowa i Trening Modeli XGBoost dla BTC i ETH	56
11	Ocena Modeli	57
12	Wizualizacje Wyników Modeli	59
12.1	Wykres Liniowy Rzeczywistych i Przewidywanych Cen Zamknięcia dla BTC i ETH	59
12.2	Wykres Reszt dla Przewidywanych Cen Zamknięcia dla BTC i ETH	66
12.3	Wykres Rozkładu Błędów Predykcji Cen Zamknięcia dla BTC i ETH	73
12.4	Wykres Rozrzutu Rzeczywistych i Przewidywanych Cen Zamknięcia dla BTC i ETH	80
12.5	Wykres Skumulowanych Stóp Zwrotu Rzeczywistych i Przewidywa- nych Cen Zamknięcia dla BTC i ETH	87
13	Dashboard	94
13.1	Zapis wyników do plików CSV	94
13.2	Funkcjonalności Dashboardu	94
13.2.1	Tytuł	94
13.2.2	Tabelaryczne podsumowanie modeli	94
13.2.3	Wykres kolumnowy	95
13.2.4	Fragmentatory	95
13.2.5	Wykres Liniowy „Actual vs Predicted Price by Date”	95
13.2.6	Wykres Liniowy „Residuals by Date”	95
14	Podsumowanie	95
15	Wykaz tabel	97
16	Wykaz rysunków	97
17	Bibliografia	101

1 Streszczenie

1.1 Streszczenie

Celem pracy było zbudowanie i wytrenowanie **modelu predykcyjnego** umożliwiającego predykcję **cen zamknięcia kryptowalut** Bitcoin i Ethereum. W projekcie zbadano skuteczność różnych algorytmów, takich jak LSTM, GRU, RNN, CNN, LightGBM i XGBoost, pod kątem precyzji oszacowań. Do analizy użyto historyczne dane rynkowe, a oceniając modele posłużono się metrykami MSE, MAE i R^2 . Wyniki wykazały, że modele XGBoost i LightGBM charakteryzują się najwyższą dokładnością, zwłaszcza w dynamicznych warunkach rynkowych, w których inne modele miały trudności w prawidłowej predykcji cen. Opracowano również interaktywny dashboard, umożliwiający użytkownikom przegląd wizualizacji wyników dla poszczególnych modeli i kryptowalut. Praca dostarcza cennych wniosków dla inwestorów i analityków zajmujących się rynkiem kryptowalut.

1.2 Słowa Kluczowe

Modele Predykcyjne, Kryptowaluty, Cena Zamknięcia

2 Wykaz skrótów

BTC Bitcoin

ETH Ethereum

LSTM Long Short-Term Memory (Długoterminowa Pamięć Krótkotrwała)

RNN Recurrent Neural Network (Rekurencyjna sieć neuronowa)

GRU Gated Recurrent Unit (Jednostka Rekurencyjna z Bramkowaniem)

CNN Convolutional Neural Networks (Konwolucyjne sieci neuronowe)

LightGBM Light Gradient Boosting Machine (Lekka Gradientowa Maszyna Wzmacniająca)

XGBoost Extreme Gradient Boosting (Ekstremalne Wzmacnianie Gradientowe)

MSE Recurrent Neural Network (Średni błąd kwadratowy)

MAE Recurrent Neural Network (Średni błąd bezwzględny)

R^2 Recurrent Neural Network (Współczynnik determinacji)

3 Wstęp

3.1 Wprowadzenie do Tematu

W ciągu ostatnich lat kryptowaluty stały się jednym z najdynamiczniej rozwijających się segmentów rynku finansowego, a ich popularność nieustannie rośnie. Wzrost ich popularności jest ściśle powiązany z rosnącym zainteresowaniem zarówno inwestorów instytucjonalnych, jak i indywidualnych.

Pomimo powszechnego uznania jako alternatywne środki przechowywania kapitału, charakterystyka kryptowalut jest bardzo zmienna, co powoduje, że przewidywanie ich przyszłych cen jest niezwykle trudne. W konsekwencji wiele instytucji jak i profesjonalnych traderów oraz zwykłych inwestorów poszukuje sposobów na stworzenie czy też już działających skutecznych modeli uczenia maszynowego przewidujących zmiany cen rozmaitych kryptowalut.

Praca analizuje możliwości wykorzystania nowoczesnych metod uczenia maszynowego do przewidywania cen wybranych kryptowalut – Bitcoin oraz Ethereum. Kończącym etapem pracy jest interaktywny dashboard, który umożliwi docelowym użytkownikom analizę tych przewidywań w sposób przystępny dla laicznego odbiorcy.

3.2 Problem Badawczy

Podstawowym problemem badawczym pracy jest znalezienie najlepszego modelu predykcyjnego dla kryptowalut Bitcoin i Ethereum, tzn. takiego, który umożliwi na jak najdokładniejsze prognozowanie ich cen zamknięcia ('close') na podstawie wybranego zbioru historycznych danych oraz wskaźników technicznych.

Cena zamknięcia 'close' została wybrana jako parametr do predykcji, gdyż jest ona powszechnie uznawana za najbardziej reprezentatywną wartość w danym okresie. Jak podaje literatura:

*"W przypadku notowań prowadzonych w systemie ciągłym na aktywnym rynku przybliżeniem wartości godziwej jest zazwyczaj cena zamknięcia (kurs zamknięcia) z dnia wyceny (cena, po której zawarta została ostatnia transakcja w dniu wyceny)."*¹

Przed wszystkim praca skupi się na zbadaniu, jak różne algorytmy uczenia maszynowego radzą sobie w prognozowaniu wartości aktyw na rynku kryptowalutowym.

3.3 Cele Pracy

Celem pracy jest:

1. Opracowanie systemu predykcyjnego służącego do prognozowania cen wybranych kryptowalut – Bitcoin i Ethereum, przy użyciu algorytmów uczenia maszynowego, w tym głębokiego uczenia.

¹Komunikat Ministra Finansów z dnia 5.01.2024 r. w sprawie ogłoszenia uchwały Komitetu Standardów Rachunkowości w sprawie przyjęcia Stanowiska Komitetu Standardów Rachunkowości w sprawie ustalania wartości godziwej dla potrzeb rozliczania połączeń jednostek metodą nabycia. Dz. Urz. Min. Fin. z 2024 r., poz. 23. Dostępne pod adresem: <https://przepisy.gofin.pl/przepisy,4,16,181,8193,,komunikat-ministra-finansow-z-dnia-5012024-r-w-sprawie.html>

2. Porównanie efektywności modeli predykcyjnych takich jak CNN, RNN, LSTM, GRU, XGBoost, LightGBM na podstawie miar jakości MSE, MAE, R^2 .
3. Utworzenie interaktywnego dashboardu, który umożliwi użytkownikowi wybór aktywa, okresu czasu oraz typu transakcji, a następnie wyświetli odpowiednie wizualizacje bazujące na wynikach prognoz.

3.4 Motywacja

Rynek kryptowalut cechujący się znaczną zmiennością oraz obecnie dynamicznym rozwojem jest wyzwaniem dla jego analityków - niezwykle ciężko przewidzieć przyszłe wartości aktywów tego rynku. Brakuje uniwersalnych rozwiązań, opartych na nowoczesnych technologiach, które pozwoliłyby na dokładne prognozowanie cen kryptowalut. Użycie nowoczesnych algorytmów uczenia maszynowego poszerza możliwości analizy danych historycznych. Dzięki temu możemy identyfikować wzorce i zależności, które byłyby trudne do wychwycenia tradycyjnymi metodami. Praca wykorzystuje potencjał narzędzi predykcyjnych, poprzez użycie technologii uczenia maszynowego, tak aby wspierać osoby i instytucje zainteresowane inwestycjami na rynku kryptowalut.

3.5 Zakres Pracy

Zakres pracy obejmuje:

1. Analizę wybranych algorytmów uczenia maszynowego - RNN, LSTM, GRU, CNN, XGBoost oraz LightGBM. Praca skupia się na zdefiniowaniu ich przydatności pod kątem prognozowania cen kryptowalut Bitcoin i Ethereum. Historyczne dane rynkowe obu aktywów zostały przetworzone, dokonano ich analizy, zaimplementowano modele predykcyjne i wytrenowano je na wspomnianych danych. Końcowo przeprowadzono porównanie efektywności algorytmów uczenia maszynowego przy użyciu wymienionych miar jakości - MSE, MAE, R^2 .
2. Wyniki pracy zostały zaprezentowane w przystępnej postaci - interaktywnego i intuicyjnego dashboardu, umożliwiającego analizę prognoz w zależności od wybranej kryptowaluty, okresu czasu oraz pozostałych parametrów.

3.6 Ryzyka Projektowe

Podczas realizacji projektu mogą pojawić się następujące wyzwania, które mogą negatywnie wpłynąć na precyzję wyników oraz proces analizy. Przede wszystkim zagrożeniem jest duża niestabilność rynku kryptowalut może wpływać negatywnie na prognozy. Szczególnie w przypadku zastosowania złożonych modeli neuronowych, takich jak RNN, LSTM czy GRU, może wystąpić zjawisko overfittingu. Overfitting według artykułu naukowego:

*"Overfitting occurs when a model is too complex or fits the training data too closely, making it difficult to generalize to new or unseen data. This can result in the capture of small patterns or noise in the training data that are not representative of the broader data set."*²

Tłumaczenie własne: Overfitting ma miejsce, gdy model jest zbyt złożony lub dopasowuje się zbyt ściśle do danych treningowych, co utrudnia uogólnienie wyników na nowe lub nieznane dane. Może to skutkować uchwyceniem drobnych wzorców lub szumów w danych treningowych, które nie są reprezentatywne dla szerszego zbioru danych.

4 Metodyka pracy

W pracy zastosowano nowoczesne algorytmy uczenia maszynowego w celu przeprowadzenia analizy predykcyjnej cen kryptowalut Bitcoin i Ethereum. Przyjęte założenia obejmują:

4.1 Charakterystyka Źródła Danych

Dane historyczne zostały pobrane z bazy danych 'Crypto currencies daily prices', umieszczonej na platformie Kaggle, gdzie dostępne są dane dla 123 kryptowalut. W projekcie skupiono się na kryptowalutach Bitcoin i Ethereum.

Zakres danych: Okres zbierania danych rozpoczął się dla kryptowaluty Bitcoin 2010-07-17, a dla Ethereum 2015-08-07, i dla obu aktywów skończył się 2024-12-09. Dane zawierają 6 kolumn: symbol kryptowaluty, datę, dzienne ceny otwarcia, zamknięcia, maksymalne i minimalne wartości.

4.2 Przetwarzanie Danych

- Czyszczenie danych: Usunięto braki danych i uzupełniono brakujące wartości za pomocą metod statystycznych.
- Normalizacja: Dane zostały przeskalowane do zakresu [0..1], aby ujednolicić zakres zmiennych wejściowych.

4.3 Metody Badawcze

Algorytmy uczenia maszynowego:

1. Sekwencyjne modele sieci neuronowych: RNN, LSTM, GRU.
2. Konwolucyjne sieci neuronowe (CNN).
3. Modele oparte na drzewach decyzyjnych: XGBoost, LightGBM.

²Subramanian, J., & Simon, R. (2013). *Overfitting in Prediction Models - Is It a Problem Only In High Dimensions?*. Contemporary Clinical Trials, 36(2). DOI: 10.1016/j.cct.2013.06.011

4.4 Metryki i Kryteria Ewaluacji

Metryki oceny modeli:

1. Mean Squared Error (MSE): Średni błąd kwadratowy.
2. Mean Absolute Error (MAE): Średni błąd bezwzględny.
3. R^2 : Współczynnik determinacji.

Kryteria sukcesu:

1. Charakterystyka najlepszego modelu:
 - Minimalizuje MSE/MAE, w zakresie $[0, \infty]$.
 - Maksymalizuje R^2 , w zakresie $[0..1]$.
2. Intuicyjna prezentacja wyników w dashboardzie.

4.5 Narzędzia i Technologie

Język programowania:

Python został wybrany jako główny język programowania. Jest to wszechstronny, zaawansowany i wiodący język programowania do analizy danych i uczenia maszynowego.

Środowiska pracy:

1. Jupyter Notebook: Wykorzystany do tworzenia kodu analitycznego oraz podstawowej wizualizacji wyników.
2. Google Colab: Użyty do realizacji analizy predykcyjnej, która wiąże się z obliczeniami wymagającymi większej mocy obliczeniowej - umożliwia on wykorzystanie GPU/TPU oraz możliwości pracy w chmurze.

Biblioteki:

1. TensorFlow i Keras do budowy i treningu sieci neuronowych.
2. Scikit-learn do wstępnej analizy danych, inżynierii cech i ewaluacji modeli.
3. XGBoost i LightGBM do implementacji modeli opartych na drzewach decyzyjnych.
4. Matplotlib i Seaborn do wizualizacji wyników analizy.

Dashboard: Interaktywny dashboard został opracowany z wykorzystaniem narzędzia Power BI. Narzędzie to pozwala na wizualizację wyników prognoz w sposób intuicyjny i przyjazny dla użytkownika.

4.6 Plan Działania

1. Przygotowanie i przetworzenie danych.
2. Wizualizacja danych.
3. Budowa oraz optymalizacja modeli predykcyjnych.
4. Ewaluacja modeli.
5. Wizualizacja wyników.
6. Prezentacja i podsumowanie wyników w interaktywnym dashboardzie.

5 Przegląd literatury

5.1 Historyczny Kontekst Prognozowania Cen Kryptowalut

Prognozowanie cen kryptowalut jest dużym wyzwaniem ze względu na ich charakterystykę - dużą zmienność oraz specyfikę rynku. W początkowych latach istnienia Bitcoin (2009) i innych kryptowalut, kryptowaluty były traktowane przede wszystkim jako alternatywne środki płatnicze. Rynek był rynkiem bardzo młodym, a zmienność wartości aktywów wynikała z niepewności co do ich przyszłości - ich wartość bazowała na ogólnych trendach rynkowych.

Wraz ze spopularyzowaniem kryptowalut ich rynek rozrósł się i rozwinął - powstały pierwsze próby przewidywania ich cen poprzez użycie prostych metod statystycznych, takich jak średnie ruchome i analiza regresji. Do początkowych prób używano również klasycznych narzędzi analizy technicznej, takich jak wskaźniki RSI (Relative Strength Index) i MACD (Moving Average Convergence Divergence).

Rozwój technologii komputerowych i algorytmów uczenia maszynowego spowodował kolejne, bardziej zaawansowane podejścia do predykcji cen. Wspomniane algorytmy umożliwiły lepsze modelowanie skomplikowanych zależności danych rynkowych. Do dominacji w badaniach naukowych skomplikowanych algorytmów uczenia maszynowego przyczyniła się rosnąca moc obliczeniowa i dostępność dużych zbiorów danych.

5.2 Podejścia Oparte na Uczeniu Maszynowym w Prognozowaniu Cen Kryptowalut

Uczenie maszynowe jest obecnie jednym z kluczowych narzędzi prognozowania cen kryptowalut. Pozwala na wykrywanie wzorców w obszernych zbiorach danych i modelowanie skomplikowanych zależności pomiędzy różnymi czynnikami oddziałującymi na rynek.

W literaturze dominują dwa główne podejścia: modele klasyfikacyjne i regresyjne. Modele klasyfikacyjne służą do predykcji kierunku zmiany ceny (np. wzrost, spadek, brak zmian), z kolei modele regresyjne są stosowane do predykcji dokładnej wartości ceny.

5.3 Analiza i Wybór Modeli Predykcyjnych

W literaturze naukowej dotyczącej predykcji cen kryptowalut szczególnie dużym zainteresowaniem cieszą się zaawansowane modele uczenia maszynowego i głębokiego uczenia. Dzięki nim jesteśmy w stanie wykrywać złożone wzorce w danych nacechowanych wysoką zmiennością. Spośród szerokiego wachlarza dostępnych modeli jednymi z najbardziej skutecznych w prognozowaniu cen kryptowalut są modele sekwencyjne, takie jak RNN, LSTM i GRU, konwolucyjne sieci neuronowe (CNN) oraz modele oparte na drzewach decyzyjnych, takie jak XGBoost i LightGBM. Każdy z tych modeli posiada unikalne cechy i mechanizmy, które powodują, że są one niezwykle przydatne w analizie danych czasowych związanych z rynkiem kryptowalut.

Szczegółowe przedstawienie sprawdzonych modeli:

1. Modele sekwencyjne (ang. Sequence Models)

Modele sekwencyjne są zaprojektowane specjalnie do pracy ze zbiorami danych, w których kolejność danych ma kluczowe znaczenie. Dobrze sprawdzają się podczas pracy na danych czasowych lub sekwencjach. Jak wskazano w literaturze:

*"Sequence Models have been motivated by the analysis of sequential data such as text sentences, time-series and other discrete sequences data. These models are especially designed to handle sequential information while Convolutional Neural Network are more adapted for processing spatial information."*³

Tłumaczenie własne: Modele sekwencyjne zostały opracowane w celu analizy danych sekwencyjnych, takich jak zdania tekstowe, szeregi czasowe i inne dyskretne dane sekwencyjne. Modele te są specjalnie zaprojektowane do obsługi informacji sekwencyjnych, podczas gdy konwolucyjne sieci neuronowe są bardziej dostosowane do przetwarzania informacji przestrzennych.

Zastosowane modele:

1.1. Model RNN (ang. Recurrent Neural Networks, pol. Rekurencyjne Sieci Neuronowe)

Model RNN jest bazowym modelem rekurencyjnym, który najlepiej sprawdza się podczas modelowania krótkoterminowych zależności. Jest natomiast mniej efektywny przy długich sekwencjach, dlatego zazwyczaj stosuje się go do prostszych problemów z danymi czasowymi. Jak podaje źródło:

³Liquet, B., Moka, S., & Nazarathy, Y. (2021). *The Mathematical Engineering of Deep Learning*, Rozdział 8: Sequence Models, s. 123. Dostępne pod adresem: <https://deeplearningmath.org/sequence-models>

*"Recurrent Neural Networks (RNN) is especially designed to deal with sequential data which is not i.i.d. RNN can tackle the following challenges from sequence data: to deal with variable-length sequences, to maintain sequence order, to keep track of long-term dependencies, to share parameters across the sequence."*⁴

Tłumaczenie własne: Rekurencyjne Sieci Neuronowe (RNN) zostały specjalnie zaprojektowane do pracy z danymi sekwencyjnymi, które nie są niezależnymi i identycznie rozkładowymi próbkami (i.i.d.). RNN radzi sobie z następującymi wyzwaniami związanymi z danymi sekwencyjnymi: obsługą sekwencji o zmiennej długości, zachowaniem kolejności sekwencji, śledzeniem długoterminowych zależności oraz współdzieleniem parametrów w obrębie sekwencji.

1.2. Model LSTM (ang. Long Short-Term Memory, pol. Długoterminowa Pamięć Krótkotrwała)

Model LSTM posiada mechanizm zapominania, dzięki czemu jest idealny do uchwytowania danych z długoterminowymi zależnościami. Jak zauważono w pracach naukowych:

*"LSTM is used to take into account long-term dependencies and was introduced by Hochreiter and Schmidhuber in 1997 to offer a solution to the vanishing gradients problem. LSTM models make each node a more complex unit with gates controlling what information is passed through rather than each node being just a simple RNN cell."*⁵

Tłumaczenie własne: Model LSTM jest używany do uwzględniania długoterminowych zależności i został wprowadzony przez Hochreitera i Schmidhubera w 1997 roku jako rozwiązanie problemu zanikających gradientów. Modele LSTM sprawiają, że każdy węzeł staje się bardziej złożoną jednostką z bramkami kontrolującymi, jakie informacje są przekazywane, zamiast aby każdy węzeł był jedynie prostą komórką RNN.

1.3. Model GRU (ang. Gated Recurrent Unit, pol. Jednostka Rekurencyjna z Bramkowaniem)

Model GRU jest również przeznaczony do modelowania sekwencji, często postrzega się go jako szybszą wersję LSTM – ma niższą złożonością obliczeniową. Literatura wskazuje, że:

*"GRU has been proposed by Cho et al. in 2014 as an alternative to the LSTM. For GRU model, there is no cell state and at each time step there are an input and hidden state. GRU is often considered a simpler and faster alternative to LSTM due to reduced computational complexity."*⁶

⁴Liquet, B., Moka, S., & Nazarathy, Y. (2021). *The Mathematical Engineering of Deep Learning*, Rozdział 8: Sequence Models, s. 123. Dostępne pod adresem: <https://deeplearningmath.org/sequence-models>

⁵Hochreiter, S., & Schmidhuber, J. (1997). *Long Short-Term Memory*. *Neural Computation*, 9(8), 1735–1780. Dostępne pod adresem: <https://direct.mit.edu/neco/article/9/8/1735/6109/Long-Short-Term-Memory>

⁶Cho, K., Van Merriënboer, B., Gulcehre, C., Bahdanau, D., Bougares, F., Schwenk, H., &

Tłumaczenie własne: Model GRU został zaproponowany przez Cho i wsp. w 2014 roku jako alternatywa dla LSTM. W modelu GRU nie ma stanu komórki, a na każdym kroku czasowym istnieje wejście i stan ukryty. GRU jest często uważany za prostszą i szybszą alternatywę dla LSTM ze względu na zmniejszoną złożoność obliczeniową.

1. Modele konwolucyjne (ang. Convolutional Models)

Modele konwolucyjne są modelami dobrze sprawdzającymi się do analizy wzorców w danych. W pracach naukowych zauważono:

*"Convolutional neural networks are distinguished from other neural networks by their superior performance with image, speech or audio signal inputs. They excel at image-related tasks, such as image recognition, object classification, and pattern recognition."*⁷

Tłumaczenie własne: Konwolucyjne sieci neuronowe wyróżniają się na tle innych sieci neuronowych swoją wyjątkową wydajnością w przypadku danych wejściowych w postaci obrazów, dźwięku lub sygnałów audio. Świetnie sprawdzają się w zadaniach związanych z obrazami, takich jak rozpoznawanie obrazów, klasyfikacja obiektów i rozpoznawanie wzorców.

Zastosowane modele:

1.1. Model CNN (ang. Convolutional Neural Networks, pol. Konwolucyjne Sieci Neuronowe)

Model CNN używa warstw konwolucyjnych do wykrywania wzorców w danych czasowych. Dane wyjściowe są spłaszczane, a następnie przekształcane na prognozy za pomocą warstw gęstych. Według dostępnych źródeł:

*"CNNs, in contrast, are primarily specialized for processing spatial data, such as images. They excel at image-related tasks, such as image recognition, object classification and pattern recognition."*⁸

Tłumaczenie własne: CNN są przede wszystkim wyspecjalizowane w przetwarzaniu danych przestrzennych, takich jak obrazy. Doskonale sprawdzają się w zadaniach związanych z obrazami, takich jak rozpoznawanie obrazów, klasyfikacja obiektów oraz rozpoznawanie wzorców.

Bengio, Y. (2014). *Learning Phrase Representations using RNN Encoder–Decoder for Statistical Machine Translation*. arXiv preprint arXiv:1406.1078. Dostępne pod adresem: <https://arxiv.org/abs/1406.1078>

⁷Gillis, A. S., Craig, L., & Awati, R. (2024). *What is a convolutional neural network (CNN)?*. Dostępne pod adresem: <https://www.techtarget.com/searchenterpriseai/definition/convolutional-neural-network>

⁸Gillis, A. S., Craig, L., & Awati, R. (2024). *What is a convolutional neural network (CNN)?*. Dostępne pod adresem: <https://www.techtarget.com/searchenterpriseai/definition/convolutional-neural-network>

1. Modele drzew decyzyjnych (ang. Decision Tree-Based Models)

Modele drzew decyzyjnych działają w oparciu o dzielenie danych na podzbiory poprzez użycie warunków decyzyjnych, co sprawia, że są efektywne zarówno w regresji, jak i klasyfikacji. Zgodnie z ustaleniami w literaturze:

*"Decision tree models enable the creation of classification systems that predict or classify future observations based on a set of decision rules. Given data divided into classes of interest (e.g., high-risk loans versus low-risk loans, subscribers versus prepaid users, voters versus non-voters, bacteria types), these data can be used to build rules that classify old or new observations with maximum accuracy."*⁹

Tłumaczenie własne: Modele drzew decyzyjnych umożliwiają tworzenie systemów klasyfikacji, które przewidują lub klasyfikują przyszłe obserwacje na podstawie zestawu reguł decyzyjnych. Mając dane podzielone na interesujące nas klasy (np. kredyty o wysokim ryzyku kontra kredyty o niskim ryzyku, abonenci kontra użytkownicy prepaid, głosujący kontra niegłosujący, typy bakterii), możemy wykorzystać te dane do budowania reguł klasyfikujących stare lub nowe obserwacje z maksymalną dokładnością.

Zastosowane modele:

1.1. LightGBM (ang. Light Gradient Boosting Machine, pol. Lekka Gradientowa Maszyna Wzmacniająca)

Model LightGBM to model wysoce wydajny, zoptymalizowany pod kątem dużych zbiorów danych. W badaniach naukowych stwierdzono, że:

*"LightGBM uses histogram-based algorithms that bucket continuous feature values into discrete bins. This speeds up training and reduces memory usage."*¹⁰

Tłumaczenie własne: LightGBM wykorzystuje algorytmy oparte na histogramach, które grupują ciągłe wartości cech w dyskretne przedziały. To przyspiesza proces treningu i zmniejsza zużycie pamięci.

1.2. Model XGBoost (ang. Extreme Gradient Boosting, pol. Ekstremalne Wzmacnianie Gradientowe)

Model XGBoost jest popularnym modelem z powodu wysokiej dokładności i możliwości tuningu jego hiperparametrów, głównie stosowany do analizy danych czasowych i prognozowania. Według dokumentacji modelu XGBoost:

⁹IBM. (n.d.). *Decision tree models*. Dostępne pod adresem: <https://www.ibm.com/docs/pl/spss-modeler/saas?topic=trees-decision-tree-models>

¹⁰Vaishnavi, Y. (n.d.). *Light GBM*. Dostępne pod adresem: <https://medium.com/@vaishnaviy502/light-gbm-c11e06b53479>

*"XGBoost is an optimized distributed gradient boosting library designed to be highly efficient, flexible and portable. It implements machine learning algorithms under the Gradient Boosting framework."*¹¹

Tłumaczenie własne: XGBoost jest zoptymalizowaną, rozproszoną biblioteką gradient boosting zaprojektowaną tak, aby była wysoce wydajna, elastyczna i przenośna. Implementuje algorytmy uczenia maszynowego w ramach Gradient Boosting.

5.4 Metryki Ewaluacji Modeli Predykcyjnych

Do ewaluacji jakości i skuteczności modeli prognozujących ceny aktywów używa się odpowiednich metryk. Najczęściej stosowanymi metrykami są:

1. MSE (ang. Mean Squared Error, pl. Średni Błąd Kwadratowy)

Mierzy średnią różnicę kwadratów między wartościami rzeczywistymi a prognozowanymi.

*"The Mean Squared Error represents the average of the squared differences between the actual and predicted values in the dataset. It measures the variance of the residuals and is particularly sensitive to large errors, penalizing them more strongly."*¹²

Tłumaczenie własne: Średni błąd kwadratowy (MSE) to średnia kwadratów różnic pomiędzy rzeczywistymi a przewidywanymi wartościami w zbiorze danych. Mierzy wariancję reszt, będąc szczególnie wrażliwym na duże błędy, które są karane bardziej surowo.

$$MSE = \frac{1}{N} \sum_{i=1}^N (y_i - \hat{y}_i)^2$$

Gdzie

- N - liczba obserwacji w zbiorze danych,
- y_i - rzeczywista wartość,
- $\hat{y}_i$ - przewidywana wartość.

¹¹Chen, T., & Guestrin, C. (n.d.). *XGBoost Documentation*. Dostępne pod adresem: <https://xgboost.readthedocs.io/en/stable/>

¹²Chugh, A. (2020). *MAE, MSE, RMSE, Coefficient of Determination, Adjusted R Squared — Which Metric is Better?*. Analytics Vidhya. Dostępne pod adresem: <https://medium.com/analytics-vidhya/mae-mse-rmse-coefficient-of-determination-adjusted-r-squared>

2. MAE (ang. Mean Absolute Error, pl. Średni Błąd Bezwzględny)

Mierzy średnią różnicę wartości absolutnych między wartościami rzeczywistymi a prognozowanymi.

*"The Mean Absolute Error represents the average of the absolute differences between the actual and predicted values in the dataset. It measures the average magnitude of residuals, offering a more robust metric for datasets with outliers."*¹³

Tłumaczenie własne: Średni błąd bezwzględny (MAE) to średnia bezwzględnych różnic pomiędzy rzeczywistymi a przewidywanymi wartościami w zbiorze danych. Mierzy średnią wielkość reszt i jest bardziej odporny na obecność wartości odstających.

$$MAE = \frac{1}{N} \sum_{i=1}^N |y_i - \hat{y}_i|$$

Gdzie:

- N - liczba obserwacji w zbiorze danych,
- y_i - rzeczywista wartość,
- $\hat{y}_i$ - przewidywana wartość.

3. R^2 (ang. R-squared, Coefficient of Determination, pl. Współczynnik Determinacji)

Mierzy jaką część wariancji wartości rzeczywistych model jest w stanie uchwycić.

*"R-squared represents the proportion of variance in the dependent variable explained by the independent variables in the model. It quantifies how well the predictor variables explain the variability of the response variable. Values closer to 1 indicate a better fit."*¹⁴

Tłumaczenie własne: Współczynnik determinacji (R^2) mierzy proporcję wariancji w zmiennej zależnej wyjaśnianą przez zmienne niezależne w modelu. Wskazuje, jak dobrze zmienne predykcyjne tłumaczą zmienność zmiennej odpowiedzi. Wartości zbliżone do 1 oznaczają lepsze dopasowanie modelu.

¹³Chugh, A. (2020). *MAE, MSE, RMSE, Coefficient of Determination, Adjusted R Squared — Which Metric is Better?*. Analytics Vidhya. Dostępne pod adresem: <https://medium.com/analytics-vidhya/mae-mse-rmse-coefficient-of-determination-adjusted-r-squared>

¹⁴Chugh, A. (2020). *MAE, MSE, RMSE, Coefficient of Determination, Adjusted R Squared — Which Metric is Better?*. Analytics Vidhya. Dostępne pod adresem: <https://medium.com/analytics-vidhya/mae-mse-rmse-coefficient-of-determination-adjusted-r-squared>

$$R^2 = 1 - \frac{\sum_{i=1}^N (y_i - \hat{y}_i)^2}{\sum_{i=1}^N (y_i - \bar{y})^2}$$

Gdzie:

- N - liczba obserwacji w zbiorze danych,
- y_i - rzeczywista wartość,
- $\hat{y}_i$ - przewidywana wartość,
- $\bar{y}$ - średnia wartość rzeczywistych danych.

5.5 Podsumowanie Przeglądu Literatury

Przegląd literatury wskazuje, że do dokładnego prognozowania cen kryptowalut niezbędne są zaawansowane metody analizy danych, w szczególności algorytmy uczenia maszynowego i głębokiego uczenia. Modele takie jak LSTM, GRU, RNN, CNN, XGBoost i LightGBM są często stosowane w predykcji cen aktywów. Dzięki nim jesteśmy w stanie uchwycić wzorce w danych o dużej zmienności. Podczas predykcji cen kryptowalut należy również wziąć pod uwagę wyzwania wiążące się z tym przedsięwzięciem, takie jak duża zmienność rynku i ryzyko nadmiernego dopasowania modeli (tzw. overfitting), które mogą wpływać na jakość predykcji.

6 Zbiór Danych

Zbiór danych użyty w pracy pochodzi z platformy Kaggle i nosi nazwę „Cryptocurrencies daily prices”. Zbiór jest dostępny pod linkiem: <https://www.kaggle.com/datasets/svaningelgem/crypto-currencies-daily-prices/data> i zawiera dane najbardziej popularnych 123 kryptowalut. Popularność kryptowalut jest zdefiniowana na podstawie kapitalizacji rynkowej waluty – łącznej wartości wszystkich dostępnych jednostek danego aktywa na rynku.

*"Kapitalizacja rynkowa to miara całkowitej wartości rynkowej danego aktywa. W przypadku kryptowalut oblicza się ją poprzez pomnożenie bieżącej ceny pojedynczego tokena przez liczbę monet w obiegu"*¹⁵

Dane podzielone zostały na pliki zgodnie z kryptowalutami - każda kryptowaluta znajduje się w osobnym pliku, w formacie CSV, nazwanym jej powszechnie używanym skrótem tkz. symbolem giełdowym lub symbolem notowania, który służy do identyfikowania kryptowaluty na giełdach. Przykładowo BTC.csv - plik zawierający dane dotyczące kryptowaluty Bitcoin, a ETH.csv - plik zawierający dane dotyczące kryptowaluty Ethereum.

Dane obejmują okres od 17 lipca 2010 roku do 9 grudnia 2024 roku dla kryptowaluty Bitcoin (5260 rekordów) oraz 7 sierpnia 2015 roku dla Ethereum (3413

¹⁵Chodyniecki, P. (2025). *Czym jest kapitalizacja rynkowa kryptowalut i jak wpływa na inwestycje?*. Quark Blog. Dostępne pod adresem: <https://quark.house/blog/czym-jest-kapitalizacja-rynkowa-kryptowalut/>

rekordów). Aktualizowane były w tym okresie raz dziennie. Na takim zbiorze danych, możliwe jest zatem wykonanie analizy szeregów czasowych oraz modelowanie prognoz cen.

Zbiór jest wielowymiarowy – każdy plik przypisany do danej kryptowaluty, posiada 6 zmiennych (kolumn):

1. 'Ticker'

Reprezentuje symbol giełdowy, który wskazuje na kryptowalutę, której dotyczy dany plik.

*"A ticker symbol is a short combination of letters that is used to represent an asset, stock, or cryptocurrency token on various exchanges, swapping services, and other DeFi solutions."*¹⁶

Tłumaczenie własne: Symbol giełdowy to krótka kombinacja liter używana do reprezentowania aktywów, akcji lub tokenów kryptowalutowych na różnych giełdach, usługach wymiany oraz innych rozwiązaniach DeFi.

2. 'Date' (pl. data)

Przedstawia datę pobrania danych dla danego rekordu.

3. 'Open' (pl. cena otwarcia)

Oznacza cenę, po której dana kryptowaluta rozpoczyna handel w danym dniu.

*"Open can refer to the price at which a cryptocurrency opens at a time period, for example at the start of the day."*¹⁷

Tłumaczenie własne: Cena otwarcia/zamknięcia może odnosić się do ceny, po której kryptowaluta otwiera się w danym okresie czasu, na przykład na początku dnia; oraz do ceny, po której kryptowaluta zamyka się w danym okresie czasu, na przykład na końcu dnia.

4. 'High' (pl. cena najwyższa)

Najwyższa cena osiągnięta przez kryptowalutę w ciągu danego dnia.

*"High - In the context of a 24-hour trading period, high refers to the highest price reached by Bitcoin or other assets during the 24-hour period."*¹⁸

Tłumaczenie własne: W kontekście 24-godzinnego okresu handlowego, szczyt odnosi się do najwyższej ceny osiągniętej przez Bitcoina lub inne aktywa w ciągu 24 godzin.

¹⁶CoinMarketCap Academy. *Glossary: Ticker Symbol*. Dostępne pod adresem: <https://coinmarketcap.com/academy/glossary/ticker-symbol>

¹⁷CoinMarketCap Academy. *Glossary: Open/Close*. Dostępne pod adresem: <https://coinmarketcap.com/academy/glossary/open-close>

¹⁸Bitget Academy. *Crypto Trading Terminology for Beginners: High/Low*. Dostępne pod adresem: <https://www.bitget.com/pl/academy/crypto-trading-terminology-for-beginners>

5. 'Low' (pl. cena najniższa)

Najniższa cena osiągnięta przez kryptowalutę w ciągu danego dnia.

*"Low - In the context of a 24-hour trading period, low refers to the lowest price reached by Bitcoin or other assets during the 24-hour period."*³

Tłumaczenie własne: W kontekście 24-godzinnego okresu handlowego, dołek odnosi się do najniższej ceny osiągniętej przez określone aktywa podczas 24-godzinnego cyklu handlowego.

6. 'Close' (pl. cena zamknięcia)

To cena, po której kryptowaluta kończy handel w danym dniu.

*"Close can refer to the price at which a cryptocurrency closes at a time period, for example at the end of the day."*²

Tłumaczenie własne: Cena otwarcia/zamknięcia może odnosić się do ceny, po której kryptowaluta otwiera się w danym okresie czasu, na przykład na początku dnia; oraz do ceny, po której kryptowaluta zamyka się w danym okresie czasu, na przykład na końcu dnia.

7 Instalacja i Import Bibliotek

7.1 Instalacja Bibliotek

Zainstalowano niezbędne biblioteki do analizy i wizualizacji danych oraz budowy i treningu modeli:

1. kagglehub: Pozwala na pobieranie zbiorów danych bezpośrednio z platformy Kaggle do środowiska pracy.
2. xgboost: Implementuje algorytm gradientowego boostingu na drzewach decyzyjnych.
3. lightgbm: Implementuje algorytm gradientowego boostingu zoptymalizowany pod kątem wydajności i zużycia pamięci.
4. mplfinance: Umożliwia tworzenie wizualizacji finansowych w sposób dostosowany do rynków finansowych, np. wykresów świecowych, które są używane do analizy zmian cen kryptowalut.
5. `dask[dataframe]`: Framework używany przy dużych zbiorach danych, który służy do równoległego przetwarzania danych, jednocześnie pozwalając na realizację tego zadania bez przekraczania limitów pamięci operacyjnej; rozszerza możliwości biblioteki pandas.

7.2 Import Bibliotek

Poniżej znajdują się biblioteki, które były niezbędne do zrealizowania pracy wraz z ich ogólnym zastosowaniem w formacie "nazwa biblioteki: jej zastosowanie":

Biblioteki do manipulacji i analizy danych:

1. pandas: manipulacja danymi, analiz i tworzenie wizualizacji szeregów czasowych (np. wykresów autokorelacji).
2. numpy: operacje numeryczne i manipulacja tablicami.

Biblioteki do wizualizacji danych:

1. mplfinance: tworzenie wizualizacji finansowych, takich jak wykresy świecowe.
2. matplotlib.pyplot: tworzenie statycznych, animowanych i interaktywnych wizualizacji.
3. seaborn: zaawansowana wizualizacja danych, oparta na bibliotece Matplotlib.

Biblioteki do przetwarzania danych i oceny modeli:

1. sklearn.preprocessing.MinMaxScaler: skalowanie cech do znormalizowanego zakresu.
2. sklearn.metrics: ocena modeli regresyjnych za pomocą metryk: błąd kwadratowy (MSE), średni błąd absolutny (MAE) oraz współczynnik determinacji (R^2).

Biblioteki do modeli uczenia maszynowego:

1. tensorflow.keras.models.Sequential: budowa sekwencyjnych modeli sieci neuronowych.
2. tensorflow.keras.layers: dodawanie różnych warstw, takich jak: Dense, Dropout, Conv1D.
3. tensorflow.keras.preprocessing.sequence.TimeseriesGenerator: generowanie danych szeregów czasowych dla modeli.
4. lightgbm.LGBMRegressor: trenowanie modeli regresji gradientowego boostingu LightGBM.
5. xgboost.XGBRegressor: trenowanie modeli regresji gradientowego boostingu XGBoost.

Biblioteki do analizy szeregów czasowych:

1. statsmodels.tsa.seasonal.seasonal_decompose: dekompozycja szeregów czasowych na składowe: trend, sezonowość i reszty.
2. pandas.plotting.autocorrelation_plot: tworzenie wykresów autokorelacji danych szeregów czasowych.

Biblioteki pomocnicze:

1. kagglehub: pobieranie zbiorów danych bezpośrednio z platformy Kaggle.
2. os: interakcja z systemem operacyjnym - obsługa plików i katalogów.

8 Pobieranie i Wstępne Przetwarzanie Danych

8.1 Pobieranie Danych

Zbiór danych został pobrany bezpośrednio z platformy Kaggle za pomocą biblioteki kagglehub. Biblioteka ta umożliwia automatyczne ściągnięcie danych bezpośrednio do środowiska pracy, eliminując potrzebę manualnego pobierania i przesyłania plików. Następnie, za pomocą funkcji `os.path.join`, wygenerowano pełne ścieżki do plików dotyczących danych o Bitcoinie i Ethereum. Dane te zostały zaimportowane do dwóch obiektów `DataFrame`: `df_btc` dla Bitcoin i `df_eth` dla Ethereum, korzystając z funkcji `pd.read_csv`.

8.2 Wstępne Przetwarzanie Danych

W ramach przygotowania danych do analizy:

1. Dodano kolumnę 'ticker', identyfikującą kryptowalutę (BTC lub ETH) w każdym obiekcie `DataFrame`.
2. Połączono obiekty `df_btc` i `df_eth` w jeden zbiorczy `DataFrame` za pomocą funkcji `pd.concat`. Po połączeniu ponownie zindeksowano rekordy, ustawiając wartość parametru `drop` w `reset_index` na `True`.
3. Przeprowadzono konwersję kolumny 'date' z formatu `String` na `DateTime`, korzystając z funkcji `pd.to_datetime`, co ułatwia operacje na szeregach czasowych.
4. Posortowano rekordy w zbiorczym `DataFrame` najpierw rosnąco według kolumny 'ticker', a następnie również rosnąco według kolumny 'date', korzystając z funkcji `df.sort_values`.

8.3 Przygotowanie Danych do Użycia w Modelu

8.3.1 Skalowanie Danych

Skalowanie danych zostało zrealizowane w celu normalizacji zakresu wartości. Operacja skalowania została przeprowadzona na danych dotyczących cen zamknięcia kryptowalut Bitcoin (BTC) i Ethereum (ETH).

Cel:

- **Normalizacja Danych:** Skalowanie danych cen zamknięcia do zakresu `[0, 1]` w celu poprawy efektywności działania algorytmów uczenia maszynowego, które są wrażliwe na różnice w skali danych wejściowych.
- **Ujednolicenie:** Zapewnienie porównywalności danych obu aktywów (BTC i ETH) poprzez zastosowanie tej samej skali.

Proces:

- Inicjalizacja obiektów skalera: Dla każdej z kryptowalut zostały utworzone dwa niezależne obiekty klasy `MinMaxScaler`:
 - `scaler_btc` - skalowanie danych dla kryptowaluty BTC.
 - `scaler_eth` - skalowanie danych dla kryptowaluty ETH.
- Podział danych: Dane zostały podzielone na podstawie wartości kolumny 'ticker' na:
 - `df_btc` - DataFrame dla kryptowaluty Bitcoin.
 - `df_eth` - DataFrame dla kryptowaluty Ethereum.
- Skalowanie cen zamknięcia: Na obu DataFrame'ach wykonano operację skalowania danych do zakresu $[0, 1]$ przy użyciu funkcji `scaler.fit_transform()`:
 - `btc_scaled` - przeskalowane dane dla BTC.
 - `eth_scaled` - przeskalowane dane dla ETH.

Korzyści:

- Lepsza wydajność modelu: Algorytmy uczenia maszynowego zazwyczaj działają lepiej na danych mieszczących się w tym samym zakresie.
- Eliminacja dominacji cech: Skalowanie usuwa problem dominacji cech o dużych wartościach nad tymi o mniejszych wartościach.

Skalowanie danych jest kluczowym krokiem w przygotowaniu danych przed ich dalszym użyciem w modelowaniu predykcyjnym.

8.3.2 Generowanie Szeregów Czasowych

Generowanie szeregów czasowych polega na przygotowaniu danych do modelowania predykcyjnego poprzez utworzenie generatorów danych szeregów czasowych bazujących na wartości cen zamknięcia aktywów Bitcoin i Ethereum.

Cel:

- **Stworzenie zestawów danych szeregów czasowych:** Wygenerowanie sekwencji danych używając przeszłych wartości w celu umożliwienia trenowania modeli, które posługują się techniką uczenia się na danych historycznych.
- **Zwiększenie efektywności:** Uporządkowanie danych tak, aby ich format był dopasowany do wejścia w algorytmach sekwencyjnych, takich jak sieci neuronowe rekurencyjne (RNN) czy LSTM.

Proces:

- **Definicja parametrów generatorów:**
 - `look_back` - liczba historycznych obserwacji stosowanych do przewidywania kolejnych wartości (ustawiona na 10).
 - `batch_size` - liczba próbek w jednej partii danych przekazywanej do modelu (ustawiona na 16).

- **Tworzenie generatorów:**

- Utworzenie generatora danych dla BTC: tworzy on sekwencję danych o długości `look_back`, używając przeskalowanych danych zamknięcia kryptowaluty BTC:

```
btc_gen = TimeseriesGenerator(btc_scaled, btc_scaled, length=look_back,
                               batch_size=batch_size)
```

- Utworzenie generatora danych dla ETH: tworzy on sekwencję danych o długości `look_back`, używając przeskalowanych danych zamknięcia kryptowaluty ETH:

```
eth_gen = TimeseriesGenerator(eth_scaled, eth_scaled, length=look_back,
                               batch_size=batch_size)
```

Korzyści:

- **Strukturalizacja danych:** Przekształcenie danych w formę dostosowaną do modelowania predykcyjnego stosującego sieci neuronowe.
- **Wykorzystanie kontekstu:** Pozwolenie modelowi na analizowanie zależności w sekwencjach historycznych.
- **Automatyzacja:** Usprawnienie procesu przygotowywania danych dla dużych zbiorów danych szeregów czasowych.

Generatory stanowią ważny element przygotowania danych do modeli predykcyjnych, ponieważ umożliwiają efektywne wykorzystanie historycznych informacji do przewidywania przyszłych wartości.

9 Eksploracyjna Analiza Danych (EDA)

9.1 Inspekcja Danych

W ramach eksploracyjnej analizy danych przeprowadzono inspekcję obiektów `df_btc` i `df_eth` w celu weryfikacji ich integralności oraz poprawności struktury danych:

1. Zbadano brakujące dane w obiektach `df_btc` i `df_eth`, wykorzystując funkcje `isnull()` oraz `sum()`. Analiza wykazała, że w obu zbiorach danych brakujące wartości nie występują, co potwierdza ich integralność.
2. Zweryfikowano obecność wymaganych kolumn, takich jak `'close'` oraz `'ticker'`, które są niezbędne do dalszej analizy i modelowania. Wyświetlono wszystkie nazwy kolumn, aby potwierdzić ich obecność w zbiorze danych.
3. Przeanalizowano liczbę rekordów w zbiorach danych za pomocą funkcji `len()`. Liczba rekordów w obiekcie `df_btc` wynosi 5260, natomiast w `df_eth` – 3413.
4. Zweryfikowano poprawność filtracji wybranych kryptowalut (BTC i ETH). W tym celu wypisano dostępne tickery za pomocą `data['ticker'].unique()`, co potwierdziło, że w zbiorze znajdują się wyłącznie dane dotyczące tych dwóch kryptowalut.

9.2 Analiza Wizualna Danych Historycznych

9.2.1 Histogram Cen Zamknięcia dla BTC i ETH

Cel:


Celem wykresu jest umożliwienie analizy i porównania rozkładu cen zamknięcia Bitcoin i Ethereum poprzez wizualizację w formie histogramu i linii KDE (Kernel Density Estimator). Jak podaje literatura:

*"The Kernel Density Estimator (KDE) provides a rational and visually pleasant representation of the data distribution when the data distribution is too irregular and does not resemble any of the usual probability density functions."*¹⁹

Tłumaczenie własne: Kernel Density Estimator (KDE) dostarcza racjonalną i wizualnie atrakcyjną reprezentację rozkładu danych w sytuacjach, gdy rozkład danych jest zbyt nieregularny i nie przypomina żadnej z typowych funkcji gęstości prawdopodobieństwa.

Analiza Histogramu Cen Zamknięcia dla BTC i ETH:

- **BTC:**




Rysunek 1: Histogram Cen Zamknięcia dla BTC

- **Rozkład:** Histogram wskazuje, że ceny zamknięcia BTC są skoncentrowane głównie w przedziale 0–10 000 USD.

¹⁹J. Drapala, *Kernel Density Estimator explained step by step, Towards Data Science*. Dostępne pod adresem: <https://towardsdatascience.com>

- **Asymetria:** Rozkład jest prawoskośny – zdecydowana większość wartości znajduje się w niższych przedziałach cenowych, z ogonem ciągnącym się w stronę wyższych wartości.
- **Zmienność:** Szeroka rozpiętość cen, osiągająca nawet 100 000 USD, oznacza znaczne wahania wartości BTC.

- **ETH:**



Rysunek 2: Histogram Cen Zamknięcia dla ETH

- **Rozkład:** Ceny zamknięcia ETH są skoncentrowane poniżej 2000 USD, co sugeruje mniejszą zmienność w porównaniu do BTC.
- **Asymetria:** Rozkład prawoskośny - obecna jest większa koncentracja wartości w niższych przedziałach cenowych.
- **Zmienność:** Zakres cen sięga do 5000 USD, co sugeruje wahania na rynku ETH.

Wnioski:

1. BTC: Charakteryzuje się szerszym zakresem cen i zdecydowanie większą zmiennością, co wskazuje na bardziej dynamiczny rynek.
2. ETH: Charakteryzuje się węższym zakresem cen i mniejszą zmiennością, co wskazuje na bardziej stabilny, choć nadal ryzykowny rynek.

9.2.2 Wykres Pudełkowy Cen Zamknięcia dla BTC i ETH


Cel:

Celem wykresu jest wizualizacja rozkładu cen zamknięcia dla Bitcoin (BTC) i Ethereum (ETH), w celu analizy zmienności danych oraz identyfikacji wartości odstających (outliers). Ze źródeł naukowych wiadomo, że:

*"Dzięki wizualizacji za pomocą wykresu pudełkowego można łatwo zidentyfikować wartości odstające, które mogą dostarczyć istotnych informacji o skrajnych zmianach lub nietypowych trendach w danych."*²⁰

Analiza Wykresów Pudełkowych Cen Zamknięcia dla BTC i ETH:

- **BTC:**



Rysunek 3: Wykres Pudełkowy Cen Zamknięcia dla BTC


- **Rozkład:** Wykres pudełkowy dla BTC pokazuje, że wartości cen zamknięcia są głównie skoncentrowane w dolnym zakresie, poniżej 20 000 USD. Szeroki zakres „pudełka” wskazuje na dużą zmienność cen.
- **Wartości odstające:** Znacząca liczba wartości odstających, sięgających nawet 100 000 USD, wskazuje na epizody ekstremalnych wzrostów cen, które znacząco odbiegają od typowych wartości.

²⁰Encyklopedia Zarządzania.
encyklopediazarzadzania.pl

Dostępne pod adresem: <https://www.encyklopediazarzadzania.pl>

- **Zmienność:** Szeroki zakres całego wykresu sugeruje znaczne wahania cen na rynku Bitcoina, co wskazuje na mniej stabilny rynek.

- **ETH:**



Rysunek 4: Wykres Pudełkowy Cen Zamknięcia dla ETH

- **Rozkład:** Wykres pudełkowy dla ETH ilustruje bardziej skoncentrowane wartości cen zamknięcia, z węższym „pudełkiem” w porównaniu do BTC. Większa koncentracja danych wskazuje na stabilniejsze średnie wartości cen.
- **Wartości odstające:** Niewielka liczba wartości odstających powyżej 4000 USD sugeruje epizodyczne wzrosty cen, które jednak występują rzadziej niż w przypadku BTC.
- **Zmienność:** Węższe „pudełko” wskazuje na mniejsze wahania cen na rynku Ethereum, co sugeruje stabilniejszy rynek w porównaniu do Bitcoina.

Wnioski:

1. **BTC:** Wykres pudełkowy wskazuje na wyższą zmienność i dużą liczbę wartości odstających, co sugeruje bardziej dynamiczny, ale mniej stabilny rynek.
2. **ETH:** Węższy zakres „pudełka” i mniejsza liczba wartości odstających w porównaniu do BTC sugerują bardziej stabilny rynek z mniejszymi wahaniami cen.


9.2.3 Wykres Liniowy Ceny Zamknięcia w Czasie dla BTC i ETH

Cel:

Celem wykresu jest wizualizacja cen zamknięcia w czasie dla Bitcoin (BTC) i Ethereum (ETH). Przedstawienie danych w formie wykresu liniowego pozwala na obserwację długoterminowych trendów, okresów wysokiej zmienności oraz kluczowych momentów na rynku obu kryptowalut.

Analiza Wykresu Liniowego Cen Zamknięcia w Czasie dla BTC i ETH:


- **BTC:**



Rysunek 5: Wykres Liniowy Ceny Zamknięcia w Czasie dla BTC

- **Trendy:** Ceny zamknięcia Bitcoin posiadają długoterminowy trend wzrostowy z okresowymi spadkami. Najbardziej kluczowe wzrosty cen miały miejsce w latach 2017, 2021 oraz pod koniec 2024 roku.
- **Zmienność:** Rynek Bitcoin charakteryzuje się dużą zmiennością – widoczne są dynamiczne wzrosty i spadki cen w krótkich okresach czasu.
- **Szczyty:** Maksymalne ceny zamknięcia BTC osiągały wartości przekraczające nieco 100 000 USD.

- **ETH:**



Rysunek 6: Wykres Liniowy Ceny Zamknięcia w Czasie dla ETH

- **Trendy:** Ethereum również wykazuje trend wzrostowy w okresie długoterminowym. Najbardziej kluczowe wzrosty cen miały miejsce w latach 2018, 2021 oraz 2024 roku. Wzrosty cen zamknięcia dla tej kryptowaluty są mimo wszystko bardziej stopniowe w porównaniu do aktywa Bitcoin.
- **Zmienność:** Rynek ETH jest mniej zmienny niż BTC - wahania wykresu są bardziej łagodne.
- **Szczyty:** Maksymalne ceny zamknięcia ETH osiągały około 5 000 USD, co wskazuje na niższą wartość rynkową tej kryptowaluty w porównaniu do BTC.

Wnioski:

1. **BTC:** Obserwacje wywnioskowane z wykresu, takie jak dynamiczne zmiany cen oraz większa liczba gwałtownych wzrostów i spadków cen zamknięcia, wskazują na bardziej ryzykowny i niestabilny charakter rynku BTC. Jednocześnie można stwierdzić, że jest to dominująca kryptowaluta w kontekście kapitalizacji z dwóch opracowywanych aktywów w tej pracy.
2. **ETH:** Mniejsza zmienność oraz bardziej stopniowe zmiany cen zamknięcia sugerują stabilniejszy rynek ETH - może to być zatem bardziej odpowiednia kryptowaluta dla inwestorów, którzy nie są gotowi na wysokie ryzyko.


9.2.4 Wykres 30 Dniowej Średniej Kroczącej Cen Zamknięcia dla BTC i ETH

Cel:

Celem wykresu jest przedstawienie średnich kroczących cen zamknięcia z 30-dniowym oknem dla Bitcoin (BTC) i Ethereum (ETH). Wizualizacja ta pomaga w wygładzeniu krótkoterminowych fluktuacji cen, co ułatwia analizę dynamiki rynku oraz zidentyfikowanie długoterminowych trendów.

Analiza Wykresu 30 Dniowej Średniej Kroczącej Cen Zamknięcia dla BTC i ETH


- **BTC:**



Rysunek 7: Wykres 30 Dniowej Średniej Kroczącej Cen Zamknięcia dla BTC

- **Trendy:** Na wykresie średniej kroczącej dla kryptowaluty Bitcoin widać pokąźny trend wzrostowy, szczególnie widoczny w latach 2017, 2021 oraz 2024. W tych okresach można zauważyć wyraźne akumulacje wzrostów cen zamknięcia.
- **Zmienność:** Pomimo wygładzenia, średnia krocząca BTC nadal ukazuje znaczne wahania. Świadczy to o wysokiej dynamice rynku BTC.
- **Szczyty:** Maksymalne wartości średniej kroczącej dla aktywa Bitcoin sięgały blisko 80 000 USD, co pokazuje, że Bitcoin ma znaczną wartość rynkową.

- **ETH:**



Rysunek 8: Wykres 30 Dniowej Średniej Kroczącej Cen Zamknięcia dla ETH

- **Trendy:** Na wykresie średniej kroczącej dla kryptowaluty Ethereum również widać pokąźny trend wzrostowy, szczególnie widoczny w latach 2018, 2021 oraz 2024. Jednak w porównaniu do kryptowaluty BTC, są to wzrosty zdecydowanie bardziej stopniowe.
- **Zmienność:** Rynek ETH zdaje się być bardziej stabilny w porównaniu do BTC - wahania średniej kroczącej ETH są mniej dynamiczne.
- **Szczyty:** Maksymalne wartości średniej kroczącej dla aktywa Ethereum sięgały około 4 000 USD, co wykazuje mniejszą wartość rynkową ETH w porównaniu do BTC.

Wnioski:

1. **BTC:** Średnia krocząca BTC ukazuje dynamiczny i niestabilny rynek. Obecne są wyraźne okresy wzrostów i spadków wartości cen zamknięcia.
2. **ETH:** Średnia krocząca ETH cechuje się bardziej stabilnym wzorcem, co powoduje, że jest to kryptowaluta bardziej odpowiednia dla inwestorów preferujących mniejsze ryzyko.


9.2.5 Wykres Liniowy Zmian Procentowych Cen Zamknięcia dla BTC i ETH

Cel:

Celem wykresu jest ukazanie zmian procentowych cen zamknięcia dla kryptowalut Bitcoin (BTC) i Ethereum (ETH). Analiza tak przedstawionych danych umożliwia zrozumienie dynamiki wahań cen zamknięcia oraz znalezienie okresów ich intensywnych zmian.

Analiza Wykresu Liniowego Zmian Procentowych Cen Zamknięcia dla BTC i ETH:


- **BTC:**



Rysunek 9: Wykres Liniowy Zmian Procentowych Cen Zamknięcia dla BTC

- **Trendy:** Na wykresie zmian procentowych cen zamknięcia BTC widoczne są okresy dynamicznych zmian, szczególnie w latach dużych wahań rynkowych, czyli w roku 2013, 2017 oraz 2021.
- **Zmienność:** Wykres pokazuje znaczną zmienność rynku BTC - jest to rynek niestabilny, w którym występują dynamiczne i wysokie skoki wartości procentowych.
- **Szczyty:** Najbardziej ekstremalne zmiany procentowe sięgają nawet powyżej 300%, co jest typowym zjawiskiem dla kryptowaluty o wysokiej dynamice wzrostów i spadków.

- **ETH:**



Rysunek 10: Wykres Liniowy Zmian Procentowych Cen Zamknięcia dla ETH

- **Trendy:** Na wykresie zmian procentowych Ethereum zmiany są bardziej umiarkowane w porównaniu do BTC. Pomimo tego, w roku 2018, 2020 oraz 2021, zmiany były intensywne - wskazywały na szczególne momenty wzrostów i spadków wartości.
- **Zmienność:** Rynek Ethereum, choć również jest rynkiem zmiennym, wydaje się być bardziej przewidywalny niż rynek Bitcoina. Cechuje się regularniejszymi wahaniami procentowymi, co mówi o tym, że jest to rynek bardziej stabilny.
- **Szczyty:** Największe zmiany procentowe dla Ethereum osiągały około 40–50%, co oznacza, że jest to kryptowaluta o mniejszej dynamice niż Bitcoin.

Wnioski:

1. **BTC:** Zmiany procentowe BTC ukazują bardziej ryzykowny, dynamiczny i niestabilny charakter rynku tej kryptowaluty. Ekstremalne wahania cen powodują, że Bitcoin jest bardziej odpowiedni dla inwestorów, którym nie przeszkadza wysokie ryzyko.
2. **ETH:** Zmiany procentowe ETH wskazują na bardziej stabilny rynek w porównaniu do BTC. Mniejsze wahania procentowe sprawiają, że Ethereum jest bardziej odpowiednie dla inwestorów preferujących umiarkowane ryzyko.


9.2.6 Wykres Gęstości Cen Zamknięcia dla BTC i ETH

Cel:

Celem wykresu jest przedstawienie rozkładu gęstości cen zamknięcia dla kryptowalut Bitcoin (BTC) i Ethereum (ETH). Dzięki tej wizualizacji można zrozumieć dokładniej, jak często dane ceny pojawiają się w badanym okresie, co umożliwia identyfikację koncentracji danych, asymetrii oraz ogólnej charakterystyki rynków kryptowalut.

Analiza Wykresu Gęstości Cen Zamknięcia dla BTC i ETH:


- **BTC:**



Rysunek 11: Wykres Gęstości Cen Zamknięcia dla BTC

- **Rozkład:** Na rozkładzie gęstości cen zamknięcia BTC widzimy, że większość cen tej kryptowaluty jest skupiona w zakresie poniżej 20 000 USD. Obecny jest długi ogon rozkładu, który ciągnie się w kierunku wyższych wartości. Sugeruje to obecność pojedynczych wartości znacząco odbiegających w górę.
- **Asymetria:** Rozkład BTC jest prawoskośny, co wskazuje na większą liczbę niższych cen oraz niewiele bardzo wysokich cen zamknięcia.
- **Rozproszenie:** Szeroki zakres rozkładu świadczy o dużej zmienności rynku. Liczba cen zamknięcia, które osiągnęły wartości przekraczające 100 000 USD, jest bardzo niewielka.

- **ETH:**



Rysunek 12: Wykres Gęstości Cen Zamknięcia dla ETH

- **Rozkład:** W przypadku ETH większość cen zamknięcia jest skoncentrowana poniżej 2 000 USD. Oznacza to bardziej stabilny rynek niż BTC. Wskazuje na to również rozkład, który jest bardziej regularny - ma mniej szczytów w wyższych zakresach cenowych.
- **Asymetria:** Podobnie jak w rozkładzie BTC, rozkład ETH jest asymetryczny, lecz jego ogon rozkładu ciągnący się w kierunku wyższych cen jest krótszy, co mówi o mniejszej liczbie ekstremalnych wartości.
- **Rozproszenie:** Rynek ETH wydaje się być mniej zmienny oraz z węższym zakresem występujących cen zamknięcia w porównaniu do BTC.

Wnioski:

1. **BTC:** Rozkład gęstości cen zamknięcia BTC sugeruje, że rynek kryptowaluty charakteryzuje się dużą zmiennością, szerokim zakresem występujących cen zamknięcia i dużą liczbą wartości odstających. Dla potencjalnych inwestorów oznacza to większe ryzyko, ale również potencjalnie wyższe zyski z inwestycji.
2. **ETH:** Rozkład gęstości cen zamknięcia ETH ukazuje bardziej stabilny rynek z mniejszą zmiennością i węższym zakresem cen, co może być bardziej odpowiednie dla inwestorów preferujących umiarkowane ryzyko, ale jednocześnie takich, dla których potencjalny zysk z inwestycji nie jest najbardziej istotny.


9.2.7 Mapa Korelacji Zmiennych Rynkowych dla BTC i ETH

Cel:

Celem wykresu jest przedstawienie mapy korelacji dla zmiennych zawartych w zbiorze danych, takich jak: 'open', 'high', 'low' i 'close'. Wizualizacja korelacji zmiennych dla kryptowalut Bitcoin (BTC) i Ethereum (ETH) pozwala zrozumieć, jak poszczególne zmienne są ze sobą powiązane. Dzięki temu można pozyskać cenne informacje dotyczące zależności rynkowych.

Analiza Mapa Korelacji Zmiennych Rynkowych dla BTC i ETH:


- **BTC:**



Rysunek 13: Mapa Korelacji Zmiennych Rynkowych dla BTC

- **Korelacje:** Na mapie korelacji BTC widoczne są bardzo silne dodatnie korelacje pomiędzy wszystkimi zmiennymi, ponieważ wartości zależności są bliskie 1.0000. Najsilniejsza korelacja występuje pomiędzy zmiennymi 'open' i 'high' oraz 'low' i 'close', a ich wartości wynoszą odpowiednio 0.9996.
- **Interpretacja:** Tak wysokie wartości korelacji wskazują, że zmienne rynkowe BTC są bardzo silnie skorelowane. Jest to zjawisko charakteryzujące dość dojrzałe rynki, gdzie zmienne są ze sobą ściśle powiązane.

- **ETH:**



Rysunek 14: Mapa Korelacji Zmiennych Rynkowych dla ETH

- **Korelacje:** Mapa korelacji ETH również pokazuje, że między wszystkimi zmiennymi korelacje są bardzo silne dodatnie - wartości korelacji są bliskie 1.0000. Zależność pomiędzy zmiennymi 'open' i 'high' (0.9994) oraz 'low' i 'close' (0.9992) są nieznacznie niższe niż w przypadku kryptowaluty BTC.
- **Interpretacja:** Wyniki dla ETH potwierdzają, że zmienne rynkowe tego aktywa są również bardzo zależne od siebie, choć występuje niewielka różnica w porównaniu do BTC, co może sugerować nieco bardziej zróżnicowane zachowania rynku Ethereum oraz to, że rynek tej kryptowaluty jest młodszy niż rynek BTC.

Wnioski:

1. **BTC:** Bardzo wysokie korelacje między zmiennymi rynkowymi wskazują na niezwykle silne powiązanie cen w różnych aspektach rynkowych. Dla inwestorów jest to informacja, że zmiany w jednej zmiennej (np. ceny otwarcia) mogą z dużym prawdopodobieństwem wiązać się ze zmianą dla pozostałych zmiennych.
2. **ETH:** Podobnie jak w przypadku kryptowaluty BTC, silne korelacje pomiędzy zmiennymi rynkowymi Ethereum świadczą o spójności pomiędzy zmiennymi

rynkowymi. Ponieważ występują nieco większe różnice w wartościach zależności, możemy przypuszczać, że rynek Ethereum jest rynkiem młodszym niż rynek BTC.


9.2.8 Wykres Autokorelacji dla BTC i ETH

Cel:

Celem wykresu jest przedstawienie autokorelacji cen zamknięcia dla kryptowalut Bitcoin (BTC) i Ethereum (ETH). Analiza autokorelacji umożliwia zrozumienie, w jakim stopniu ceny zamknięcia w kolejnych dniach były od siebie zależne. Tego typu badanie bardzo pomaga w identyfikacji sezonowości, trendów i potencjalnych zależności między danymi.

Analiza Wykres Autokorelacji dla BTC i ETH:


• BTC:



Rysunek 15: Wykres Autokorelacji dla BTC

- **Trend autokorelacji:** Wykres autokorelacji dla kryptowaluty BTC ukazuje wysoki stopień dodatniej korelacji dla niskich opóźnień (lag). W miarę wzrostu opóźnienia korelacja stopniowo maleje, aż w pewnym momencie staje się ujemna.
- **Interpretacja:** Wysoka dodatnia korelacja dla małych opóźnień świadczy o tym, że ceny zamknięcia BTC w kolejnych dniach są od siebie mocno zależne. Ujemna korelacja dla większych opóźnień wskazuje na to, że występują długoterminowe cykle w danych.
- **Rozproszenie:** Obniżenie wartości korelacji dla dużych opóźnień może sugerować, że z upływem czasu wpływ historycznych danych na obecne ceny maleje.

- **ETH:**



Rysunek 16: Wykres Autokorelacji dla ETH

- **Trend autokorelacji:** W przypadku ETH trend autokorelacji jest podobny jak dla kryptowaluty BTC - dla małych opóźnień korelacja jest wysoka i dodatnia, natomiast dla większych opóźnień maleje do wartości ujemnych.
- **Interpretacja:** Podobnie jak w przypadku aktywa Bitcoin, wysoka wartość dodatniej korelacji dla niskich opóźnień sugeruje, że ceny zamknięcia ETH w kolejnych dniach są od siebie ściśle zależne.
- **Rozproszenie:** Jeszcze niższa autokorelacja dla dużych opóźnień niż dla kryptowaluty Bitcoin wskazuje, że historyczne ceny zamknięcia Ethereum mają jeszcze mniejszy wpływ na jego aktualne ceny zamknięcia niż w przypadku BTC.

Wnioski:

1. **BTC:** Autokorelacja dla BTC pokazuje silne powiązania między następującymi po sobie cenami zamknięcia w krótkim okresie. Malejąca korelacja, sięgająca nawet wartości ujemnych dla większych opóźnień, sugeruje istnienie długoterminowych cykli rynkowych. Można zatem wnioskować, że rynek BTC jest bardziej przewidywalny w krótkoterminowym horyzoncie czasowym niż w długim.

2. **ETH:** Rynek aktywa ETH charakteryzuje się bardziej dynamicznymi zmianami w porównaniu do BTC. Świadczą o tym szybsze spadki autokorelacji dla wyższych opóźnień. Pomimo tego, tak jak BTC, ETH wykazuje silne powiązania między cenami zamknięcia w krótkim okresie. Jest to informacja, która może być przydatna dla inwestorów analizujących trendy w krótkim okresie.


9.2.9 Wykres Trendu Czasowego Cen Zamknięcia dla BTC i ETH

Cel:

Celem wykresu jest przedstawienie długoterminowych trendów cen zamknięcia dla kryptowalut Bitcoin (BTC) i Ethereum (ETH). Analiza trendów umożliwia identyfikację kierunków zmian cen w czasie. Dzięki temu można lepiej zrozumieć długofalowe zachowania rynku obu aktywów.

Analiza Wykresu Trendu Czasowego Cen Zamknięcia dla BTC i ETH:


- **BTC:**



Rysunek 17: Wykres Trendu Czasowego Cen Zamknięcia dla BTC

- **Trendy:** Wykres trendów BTC charakteryzuje się wyraźnym, długoterminowym wzrostem wartości cen zamknięcia. Najbardziej zdecydowane wzrosty widoczne są w latach 2017, 2021 oraz w końcu 2024 roku - odzwierciedla to główne fale zainteresowania rynkiem Bitcoina.
- **Zmienność:** Pomimo tego, że główny trend jest rosnący, widoczne są okresy znacznych spadków, które pojawiają się po gwałtownych wzrostach. Sugeruje to wysoką zmienność rynku BTC, która jest charakterystyczna dla tego aktywa.

- **ETH:**



Rysunek 18: Wykres Trendu Czasowego Cen Zamknięcia dla ETH

- **Trendy:** W przypadku wykresu trendów aktywa ETH, charakteryzuje się on wyraźnym, długoterminowym wzrostem wartości cen zamknięcia. Najbardziej zdecydowane wzrosty widoczne są w latach 2018, 2021 oraz 2024. W przeciwieństwie do BTC, wzrosty trendu dla kryptowaluty ETH są bardziej stabilne i równomierne.
- **Zmienność:** Chociaż na rynku ETH także widoczne są wahania, zmienność wydaje się być mniejsza w porównaniu do BTC, co może świadczyć o bardziej przewidywalnym zachowaniu rynku Ethereum.

Wnioski:

1. **BTC:** Trend wskazuje na dynamiczny, ale niestabilny rynek Bitcoina. Obecne są na nim zdecydowane wzrosty na przemian z głębokimi spadkami. Czyni to BTC aktywem atrakcyjnym, ale także wymagającym dla inwestorów, którzy są skłonni ponieść wysokie ryzyko.
2. **ETH:** Stabilniejszy trend na wykresie ETH sugeruje bardziej przewidywalny rynek. Mniejsza zmienność rynku w połączeniu z obecnymi na nim długoterminowymi wzrostami powoduje, że Ethereum jest dobrym aktywem dla inwestorów szukających umiarkowanego ryzyka.


9.2.10 Wykres Reszt dla BTC i ETH

Cel:

Celem wykresu jest przedstawienie reszt (residuals) po usunięciu trendu i sezonowości z danych dotyczących cen zamknięcia kryptowalut Bitcoin (BTC) i Ethereum (ETH). Analiza reszt pozwala określić nieprzewidywalne zmiany cen, które mogą wynikać na przykład ze specyficznych wydarzeń rynkowych lub innych czynników losowych.

Analiza Wykresu Reszt dla BTC i ETH:


- **BTC:**



Rysunek 19: Wykres Reszt dla BTC

- **Charakterystyka:** Na wykresie reszt dla BTC widoczne są znaczne zmiany w wartości reszt w miarę upływu lat. Wyraźne zwiększenie amplitudy reszt ma miejsce w późniejszych latach (szczególnie od 2020 roku), co wskazuje na rosnącą zmienność na rynku Bitcoina.
- **Interpretacja:** Wysokie wartości reszt wskazują, że w tych okresach rynek BTC podlegał znacznym, nieprzewidywalnym zmianom cen. Może to wynikać z czynników zewnętrznych, takich jak zmiany regulacji, adaptacja rynkowa czy ogólne zainteresowanie inwestorów.

- **ETH:**



Rysunek 20: Wykres Reszt dla ETH

- **Charakterystyka:** W przypadku aktywa ETH amplituda reszt również wzrasta w miarę upływu czasu, jednak skala tych zmian jest zdecydowanie mniejsza niż w przypadku BTC. Największe odchylenia widoczne są w latach 2018 oraz 2021.
- **Interpretacja:** Mniejsze odchylenia w resztach dla ETH w stosunku do BTC mogą sugerować, że rynek tego aktywa jest mniej podatny na losowe czynniki zewnętrzne. Kluczowe wydarzenia rynkowe miały miejsce w latach, w których na wykresie reszt widoczne są znaczne zmiany cen zamknięcia.

Wnioski:

1. **BTC:** Analiza reszt dla BTC wskazuje na większą podatność tej kryptowaluty na losowe czynniki zewnętrzne i częstsze nieprzewidywalne zmiany cen zamknięcia w porównaniu do ETH. Rynek aktywa BTC wydaje się być bardziej dynamiczny, a co za tym idzie trudniejszy do przewidzenia.
2. **ETH:** Reszty dla ETH sugerują, że rynek ETH jest bardziej stabilnym rynkiem w porównaniu do BTC - cechuje się mniejszymi amplitudami zmian. Może to oznaczać, że rynek Ethereum jest mniej narażony na niespodziewane wahania cen. Mogą cenić to sobie inwestorzy poszukujący umiarkowanego ryzyka.

10 Budowa i Trening Modeli

10.1 Budowa i Trening Modeli LSTM dla BTC i ETH

Tworzenie i trening modeli LSTM (Long Short-Term Memory): Modele LSTM zostały stworzone dla danych szeregów czasowych cen zamknięcia 'close' kryptowalut Bitcoin (BTC) i Ethereum (ETH), które następnie zostaną wykorzystane przy tworzeniu modeli predykcyjnych.

Cel:

- **Stworzenie i wytrenowanie modeli LSTM:** Modele LSTM pozwalają na przewidywanie przyszłych wartości w oparciu o sekwencyjne dane historyczne, co jest szczególnie cenne w analizie finansowej.

Proces:

- **Definicja modelu LSTM:**

- Utworzenie modelu poprzez API Sequential, umożliwiającego prostą budowę sieci neuronowych.
- Dodanie dwóch warstw LSTM:

- * Pierwsza warstwa LSTM zwraca sekwencje danych w celu przekazania ich do kolejnej warstwy (`return_sequences=True`).
- * Druga warstwa LSTM analizuje przekazaną sekwencję i przewiduje wynik.

- Warstwa Dropout (ang. Dropout Layer)

Warstwa Dropout to zaawansowana technika regularyzacji wykorzystywana w trakcie treningu sieci neuronowych, mająca na celu zapobieganie przeuczeniu modelu. Jak zauważono w materiałach naukowych:

*"Warstwa Dropout działa poprzez losowe wyłączenie pewnej części neuronów w danej warstwie w każdej iteracji treningowej. Celem jest utrudnienie sieci zapamiętywania konkretnych zależności w danych treningowych, co poprawia jej zdolność do generalizacji i zapobiega przeuczeniu."*²¹

- Użycie gęstej warstwy wyjściowej (Dense) z jedną jednostką, która przewiduje docelową wartość. Warstwa ta jest kluczowa dla sieci neuronowych w uczeniu głębokim i charakteryzuje się tym, że wszystkie neurony tej warstwy mają połączenie z neuronami poprzedniej warstwy. Jak wyjaśnia Mirosław Mamczur:

*"Warstwa Dense umożliwia pełne połączenie neuronów, co czyni ją podstawowym elementem w sieciach głębokich."*²²

²¹The Data Game. (2024). Warstwa Dropout w Sieciach Neuronowych. Dostępne pod adresem: <https://www.towardsdatascience.com/machine-learning-part-20-dropout-keras-layers-explained-8c9f6dc4c9ab>

²²Mamczur, M. (2020). Przykładowa sieć neuronowa MLP w Tensorflow. Dostępne pod adresem: <https://www.towardsdatascience.com/machine-learning-part-20-dropout-keras-layers-explained-8c9f6dc4c9ab>

- **Kompilacja modelu:**

- Użycie optymalizatora Adam, znanego z wysokiej efektywności w problemach z dużą liczbą parametrów. O optymalizatorze Adam możemy przeczytać:

- **Kompilacja modelu:**

- * Użycie optymalizatora Adam, znanego z wysokiej efektywności w problemach z dużą liczbą parametrów. O optymalizatorze Adam możemy przeczytać:

*"Adam optimization is a stochastic gradient descent method that is based on adaptive estimation of first-order and second-order moments. According to Kingma et al., 2014, the method is 'computationally efficient, has little memory requirement, invariant to diagonal rescaling of gradients, and is well suited for problems that are large in terms of data/parameters.'"*²³

Tłumaczenie własne: Optymalizacja Adam to metoda stochastycznego spadku gradientowego oparta na adaptacyjnej estymacji momentów pierwszego i drugiego rzędu. Według Kingma i Ba (2014) metoda ta jest 'wydajna obliczeniowo, wymaga niewiele pamięci, jest odporna na skalowanie gradientów po przekątnej i dobrze dopasowana do problemów dużych pod względem danych i liczby parametrów'.

- * Funkcja błędu: średniokwadratowy błąd (MSE) jako miara różnicy między wartościami rzeczywistymi a przewidywanymi.

Korzyści:

- **Dopasowanie do sekwencyjnych danych:** Modele LSTM są dostosowane do pracy z danymi szeregów czasowych, dzięki czemu przewidywanie trendów w danych finansowych jest zazwyczaj dokładne.
- **Redukcja przetrenowania:** Użyta warstwa Dropout zwiększa umiejętność modeli do generalizacji, a tym samym zmniejsza ryzyko przeuczenia na danych treningowych.
- **Modularność:** Utworzenie oddzielnych modeli dla wybranych aktywów pozwala na elastyczne dostosowanie algorytmu i optymalizację parametrów do charakterystyki każdej kryptowaluty.

Podsumowanie: Budowa i trening modeli LSTM stanowi kluczowy krok w procesie budowy modelu predykcyjnego - umożliwia efektywne wykorzystanie danych historycznych do przewidywania przyszłych wartości.

²³Keras Documentation. *Adam Optimizer*. Dostępne pod adresem: <https://keras.io/api/optimizers/adam/>

10.2 Budowa i Trening Modeli RNN dla BTC i ETH

Tworzenie i trening modeli RNN (Recurrent Neural Networks): Modele RNN zostały stworzone dla danych szeregów czasowych cen zamknięcia 'close' kryptowalut Bitcoin (BTC) i Ethereum (ETH), które następnie zostaną wykorzystane przy tworzeniu modeli predykcyjnych.

Cel:

- **Stworzenie i wytrenowanie modeli RNN:** Modele RNN pozwalają na przewidywanie przyszłych wartości w oparciu o sekwencyjne dane historyczne, co jest szczególnie cenne w analizie finansowej.

Proces:

- **Definicja modelu RNN:**

- Utworzenie modelu poprzez API Sequential, umożliwiającego prostą budowę sieci neuronowych.
- Dodanie dwóch warstw RNN:
 - * Pierwsza warstwa RNN zwraca sekwencje danych w celu przekazania ich do kolejnej warstwy (return_sequences=True).
 - * Druga warstwa RNN analizuje przekazaną sekwencję i przewiduje wynik.

- Warstwa Dropout (ang. Dropout Layer)

Warstwa Dropout to zaawansowana technika regularyzacji wykorzystywana w trakcie treningu sieci neuronowych, mająca na celu zapobieganie przeuczeniu modelu. Jak zauważono w materiałach naukowych:

*"Warstwa Dropout działa poprzez losowe wyłączenie pewnej części neuronów w danej warstwie w każdej iteracji treningowej. Celem jest utrudnienie sieci zapamiętywania konkretnych zależności w danych treningowych, co poprawia jej zdolność do generalizacji i zapobiega przeuczeniu."*²⁴

- Użycie gęstej warstwy wyjściowej (Dense) z jedną jednostką, która przewiduje docelową wartość. Warstwa ta jest kluczowa dla sieci neuronowych w uczeniu głębokim i charakteryzuje się tym, że wszystkie neurony tej warstwy mają połączenie z neuronami poprzedniej warstwy. Jak wyjaśnia Mirosław Mamczur:

*"Warstwa Dense umożliwia pełne połączenie neuronów, co czyni ją podstawowym elementem w sieciach głębokich."*²⁵

²⁴The Data Game. (2024). Warstwa Dropout w Sieciach Neuronowych. Dostępne pod adresem: <https://www.towardsdatascience.com/machine-learning-part-20-dropout-keras-layers-explained-8c9f6dc4c9ab>

²⁵Mamczur, M. (2020). Przykładowa sieć neuronowa MLP w Tensorflow. Dostępne pod adresem: <https://www.towardsdatascience.com/machine-learning-part-20-dropout-keras-layers-explained-8c9f6dc4c9ab>

- **Kompilacja modelu:**

- Użycie optymalizatora Adam, znanego z wysokiej efektywności w problemach z dużą liczbą parametrów. O optymalizatorze Adam możemy przeczytać:

- **Kompilacja modelu:**

- * Użycie optymalizatora Adam, znanego z wysokiej efektywności w problemach z dużą liczbą parametrów. O optymalizatorze Adam możemy przeczytać:

*"Adam optimization is a stochastic gradient descent method that is based on adaptive estimation of first-order and second-order moments. According to Kingma et al., 2014, the method is 'computationally efficient, has little memory requirement, invariant to diagonal rescaling of gradients, and is well suited for problems that are large in terms of data/parameters.'"*²⁶

Tłumaczenie własne: Optymalizacja Adam to metoda stochastycznego spadku gradientowego oparta na adaptacyjnej estymacji momentów pierwszego i drugiego rzędu. Według Kingma i Ba (2014) metoda ta jest 'wydajna obliczeniowo, wymaga niewiele pamięci, jest odporna na skalowanie gradientów po przekątnej i dobrze dopasowana do problemów dużych pod względem danych i liczby parametrów'.

- * Funkcja błędu: średniokwadratowy błąd (MSE) jako miara różnicy między wartościami rzeczywistymi a przewidywanymi.

- **Inicjalizacja modeli:**

- Model `btc_rnn_model` utworzony dla BTC z definicją kształtu wejściowego (`look_back, 1`).
- Model `eth_rnn_model` utworzony dla ETH.

- **Trenowanie modeli:**

- Wytrenowanie modeli na zestawach danych wygenerowanych przez generatory szeregów czasowych (`btc_gen` i `eth_gen`).
- Oba modele, dla obu kryptowalut, są trenowane przez 20 epok, z ustawieniem `verbose=1` tak, aby wyświetlać postępy.

Korzyści:

- **Dopasowanie do sekwencyjnych danych:** Modele RNN są dostosowane do pracy z danymi szeregów czasowych, dzięki czemu przewidywanie trendów w danych finansowych jest zazwyczaj dokładne.
- **Redukcja przetrenowania:** Użyta warstwa Dropout zwiększa umiejętność modeli do generalizacji, a tym samym zmniejsza ryzyko przeuczenia na danych treningowych.

²⁶Keras Documentation. *Adam Optimizer*. Dostępne pod adresem: <https://keras.io/api/optimizers/adam/>

- **Modularność:** Utworzenie oddzielnych modeli dla wybranych aktywów pozwala na elastyczne dostosowanie algorytmu i optymalizację parametrów do charakterystyki każdej kryptowaluty.

Podsumowanie: Budowa i trening modeli RNN stanowi kluczowy krok w procesie budowy modelu predykcyjnego - umożliwia efektywne wykorzystanie danych historycznych do przewidywania przyszłych wartości.

10.3 Budowa i Trening Modeli GRU dla BTC i ETH

Tworzenie i trening modeli GRU (Gated Recurrent Unit): Modele GRU zostały stworzone dla danych szeregów czasowych cen zamknięcia 'close' kryptowalut Bitcoin (BTC) i Ethereum (ETH), które następnie zostaną wykorzystane przy tworzeniu modeli predykcyjnych.

Cel:

- **Stworzenie i wytrenowanie modeli GRU:** Modele GRU pozwalają na przewidywanie przyszłych wartości w oparciu o sekwencyjne dane historyczne, co jest szczególnie cenne w analizie finansowej.

Proces:

- **Definicja modelu GRU:**

- Utworzenie modelu poprzez API Sequential, umożliwiającego prostą budowę sieci neuronowych.
- Dodanie dwóch warstw GRU:
 - * Pierwsza warstwa GRU z 50 jednostkami, aktywacją ReLU i parametrem `return_sequences=True`, co pozwala przekazywać wyjścia do kolejnej warstwy.
 - * Druga warstwa GRU z 50 jednostkami i aktywacją ReLU.
- Warstwa Dropout (ang. Dropout Layer)

Warstwa Dropout to zaawansowana technika regularyzacji wykorzystywana w trakcie treningu sieci neuronowych, mająca na celu zapobieganie przeuczeniu modelu. Jak zauważono w materiałach naukowych:

*"Warstwa Dropout działa poprzez losowe wyłączenie pewnej części neuronów w danej warstwie w każdej iteracji treningowej. Celem jest utrudnienie sieci zapamiętywania konkretnych zależności w danych treningowych, co poprawia jej zdolność do generalizacji i zapobiega przeuczeniu."*²⁷

- Użycie gęstej warstwy wyjściowej (Dense) z jedną jednostką, która przewidywa docelową wartość. Warstwa ta jest kluczowa dla sieci neuronowych w uczeniu głębokim i charakteryzuje się tym, że wszystkie neurony tej warstwy mają połączenie z neuronami poprzedniej warstwy. Jak wyjaśnia Mirosław Mamczur:

²⁷The Data Game. (2024). Warstwa Dropout w Sieciach Neuronowych. Dostępne pod adresem: <https://www.towardsdatascience.com/machine-learning-part-20-dropout-keras-layers-explained-8c9f6dc4c9ab>

*"Warstwa Dense umożliwia pełne połączenie neuronów, co czyni ją podstawowym elementem w sieciach głębokich."*²⁸

- **Kompilacja modelu:**

- Użycie optymalizatora Adam, znanego z wysokiej efektywności w problemach z dużą liczbą parametrów. O optymalizatorze Adam możemy przeczytać:

*"Adam optimization is a stochastic gradient descent method that is based on adaptive estimation of first-order and second-order moments. According to Kingma et al., 2014, the method is 'computationally efficient, has little memory requirement, invariant to diagonal rescaling of gradients, and is well suited for problems that are large in terms of data/parameters.'"*²⁹

Tłumaczenie własne: Optymalizacja Adam to metoda stochastycznego spadku gradientowego oparta na adaptacyjnej estymacji momentów pierwszego i drugiego rzędu. Według Kingma i Ba (2014) metoda ta jest 'wydajna obliczeniowo, wymaga niewiele pamięci, jest odporna na skalowanie gradientów po przekątnej i dobrze dopasowana do problemów dużych pod względem danych i liczby parametrów'.

- Funkcja błędu: średniokwadratowy błąd (MSE) jako miara różnicy między wartościami rzeczywistymi a przewidywanymi.

- **Inicjalizacja modeli:**

- Model `btc_gru_model` utworzony dla BTC z definicją kształtu wejściowego (`look_back, 1`).
- Model `eth_gru_model` utworzony dla ETH.

- **Trenowanie modeli:**

- Wytrenowanie modeli na zestawach danych wygenerowanych przez generatory szeregów czasowych (`btc_gen` i `eth_gen`).
- Oba modele, dla obu kryptowalut, są trenowane przez 20 epok, z ustawieniem `verbose=1` tak, aby wyświetlać postępy.

Korzyści:

- **Dopasowanie do sekwencyjnych danych:** Modele GRU są dostosowane do pracy z danymi szeregów czasowych, dzięki czemu przewidywanie trendów w danych finansowych jest zazwyczaj dokładne.
- **Redukcja przetrenowania:** Użyta warstwa Dropout zwiększa umiejętność modeli do generalizacji, a tym samym zmniejsza ryzyko przeuczenia na danych treningowych.

²⁸Mamczur, M. (2020). Przykładowa sieć neuronowa MLP w Tensorflow. Dostępne pod adresem: <https://www.towardsdatascience.com/machine-learning-part-20-dropout-keras-layers-explained-8c9f6dc4c9ab>

²⁹Keras Documentation. Adam Optimizer. Dostępne pod adresem: <https://keras.io/api/optimizers/adam/>

- **Modularność:** Utworzenie oddzielnych modeli dla wybranych aktywów pozwala na elastyczne dostosowanie algorytmu i optymalizację parametrów do charakterystyki każdej kryptowaluty.

Podsumowanie: Budowa i trening modeli GRU stanowi kluczowy krok w procesie budowy modelu predykcyjnego - umożliwia efektywne wykorzystanie danych historycznych do przewidywania przyszłych wartości.

10.4 Budowa i Trening Modeli CNN dla BTC i ETH

Tworzenie i trening modeli CNN (Convolutional Neural Networks): Modele CNN zostały stworzone dla danych szeregów czasowych cen zamknięcia 'close' kryptowalut Bitcoin (BTC) i Ethereum (ETH), które następnie zostaną wykorzystane przy tworzeniu modeli predykcyjnych.

Cel:

- **Stworzenie i wytrenowanie modeli CNN:** Modele CNN pozwalają na analizę lokalnych wzorców w danych szeregów czasowych, co umożliwia dokładniejsze przewidywanie przyszłych wartości.

Proces:

- **Definicja modelu CNN:**

- Utworzenie modelu poprzez API Sequential, które pozwala na prostą i przejrzystą budowę warstwowych sieci neuronowych.
- Dodanie dwóch warstw konwolucyjnych (Conv1D):
 - * Pierwsza warstwa konwolucyjna z 64 jednostkami, rozmiarem filtra 3 i aktywacją ReLU.
 - * Druga warstwa konwolucyjna z 32 jednostkami, rozmiarem filtra 3 i aktywacją ReLU.
- Dodanie warstwy Dropout (Dropout Layer), której celem jest poprawa generalizacji modelu oraz redukcja ryzyka przetrenowania (overfittingu). Jak podaje literatura:

*"Warstwa Dropout działa poprzez losowe wyłączanie pewnej części neuronów w danej warstwie w każdej iteracji treningowej. Celem jest utrudnienie sieci zapamiętywania konkretnych zależności w danych treningowych, co poprawia jej zdolność do generalizacji i zapobiega przeuczeniu."*³⁰

- Dodana również została warstwa Flatten, służąca spłaszczeniu danych w celu przejścia do warstwy w pełni połączonej. Jak wskazuje literatura:

*"Warstwa Flatten przekształca wielowymiarowe dane w jednowymiarowy wektor, umożliwiając ich przetwarzanie przez warstwę w pełni połączoną do klasyfikacji."*³¹

³⁰The Data Game. (2024). Warstwa Dropout w Sieciach Neuronowych. Dostępne pod adresem: <https://www.towardsdatascience.com/machine-learning-part-20-dropout-keras-layers-explained-8c9f6dc4c9ab>

³¹Mamczur, M. (2021). Jak działają konwolucyjne sieci neuronowe (CNN)?. Dostępne pod adresem: <https://mirosławmamczur.pl>

- Użycie gęstej warstwy wyjściowej (Dense) z 50 jednostkami i aktywacją ReLU oraz finalnej warstwy wyjściowej (Dense) z jedną jednostką do przewidywania wartości docelowej.

• Kompilacja modelu:

- Użycie optymalizatora Adam, który jest wydajny obliczeniowo i dobrze dopasowany do dużych zbiorów danych i liczby parametrów. O optymalizatorze Adam możemy przeczytać:

*"Adam optimization is a stochastic gradient descent method that is based on adaptive estimation of first-order and second-order moments. According to Kingma et al., 2014, the method is 'computationally efficient, has little memory requirement, invariant to diagonal rescaling of gradients, and is well suited for problems that are large in terms of data/parameters.'"*³²

Tłumaczenie własne: Optymalizacja Adam to metoda stochastycznego spadku gradientowego oparta na adaptacyjnej estymacji momentów pierwszego i drugiego rzędu. Według Kingma i Ba (2014) metoda ta jest 'wydajna obliczeniowo, wymaga niewiele pamięci, jest odporna na skalowanie gradientów po przekątnej i dobrze dopasowana do problemów dużych pod względem danych i liczby parametrów'.

- Funkcja błędu: średniokwadratowy błąd (MSE) jako miara różnicy między wartościami rzeczywistymi a przewidywanymi.

• Inicjalizacja modeli:

- Model `btc_cnn_model` utworzony dla BTC z definicją kształtu wejściowego (`look_back, 1`).
- Model `eth_cnn_model` utworzony dla ETH.

• Trenowanie modeli:

- Wytrenowanie modeli na zestawach danych wygenerowanych przez generatory szeregów czasowych (`btc_gen` i `eth_gen`).
- Oba modele, dla obu kryptowalut, są trenowane przez 20 epok, z ustawieniem `verbose=1` tak, aby wyświetlać postępy.

Korzyści:

- **Dopasowanie do lokalnych wzorców:** Modele CNN są szczególnie skuteczne w analizie lokalnych wzorców w danych szeregów czasowych, co może być przydatne w analizie krótkoterminowych zmian w danych.
- **Redukcja przetrenowania:** Użyta warstwa Dropout zwiększa zdolność modeli do generalizacji, zmniejszając ryzyko przeuczenia na danych treningowych.

³²Keras Documentation. *Adam Optimizer*. Dostępne pod adresem: <https://keras.io/api/optimizers/adam/>

- **Modularność:** Utworzenie oddzielnych modeli dla wybranych aktywów pozwala na elastyczne dostosowanie algorytmu do charakterystyki każdej kryptowaluty.

Podsumowanie: Budowa i trening modeli CNN dla przewidywania wartości zamknięcia kryptowalut BTC i ETH stanowi istotny krok w procesie analizy predykcyjnej danych szeregów czasowych. Wykorzystanie warstw konwolucyjnych wraz z warstwami w pełni połączonymi umożliwia dokładne prognozowanie przyszłych wartości cen zamknięcia i analizę lokalnych zależności w danych historycznych.

10.5 Budowa i Trening Modeli LightGBM dla BTC i ETH

Tworzenie i trening modeli LightGBM (Light Gradient Boosting Machine): Modele LightGBM zostały stworzone dla danych szeregów czasowych cen zamknięcia 'close' kryptowalut Bitcoin (BTC) i Ethereum (ETH), które następnie zostaną wykorzystane przy tworzeniu modeli predykcyjnych.

Cel:

- **Stworzenie i wytrenowanie modeli LightGBM:** Modele LightGBM pozwalają na analizę danych historycznych w formie sekwencji czasowych oraz dokładniejsze przewidywanie przyszłych wartości.

Proces:

- **Definicja modelu LightGBM:**

- Utworzenie modelu jako instancji klasy LGBMRegressor, z ustawieniem losowego stanu (`random_state=42`), co zapewnia powtarzalność wyników.

- **Przygotowanie danych treningowych:**

- Dane wejściowe są przygotowane w formie sekwencji danych z przesuwającym się oknem czasowym (`sliding window`).
- W każdym kroku tworzona jest sekwencja `look_back` kolejnych wartości historycznych, która stanowi dane wejściowe (X), oraz wartość następująca bezpośrednio po tej sekwencji jako wartość docelowa (y).
- Każda sekwencja jest ręcznie spłaszczona za pomocą metody `.flatten()`, a następnie przekształcona w tablice NumPy, co umożliwia ich przetwarzanie przez model LightGBM.

- **Trenowanie modeli:**

- Modele zostały wytrenowane oddzielnie dla każdej kryptowaluty:
 - * `btc_lgbm_model` dla danych Bitcoin (BTC).
 - * `eth_lgbm_model` dla danych Ethereum (ETH).
- Funkcja `fit` modelu LightGBM została wykorzystana do dopasowania danych wejściowych (X) i wartości docelowych (y).

Korzyści:

- **Wydażność i szybkość:** Model LightGBM jest zoptymalizowany pod kątem szybkości działania, co czyni go odpowiednim dla dużych zbiorów danych i złożonych zadań predykcyjnych.
- **Elastyczność:** Model LightGBM jest elastyczny i można go łatwo dostosować do różnych typów danych oraz zadań regresyjnych.
- **Precyzyjne przewidywania:** Wykorzystanie danych historycznych w formie sekwencji pozwala modelowi LightGBM dokładnie odwzorowywać trendy w danych.

Podsumowanie: Budowa i trening modeli LightGBM dla przewidywania wartości zamknięcia kryptowalut BTC i ETH to kluczowy krok w procesie analizy predykcyjnej danych szeregów czasowych. Dzięki zastosowaniu algorytmu LightGBM możliwe jest uzyskanie dokładnych i wydajnych prognoz dla obu kryptowalut.

10.6 Budowa i Trening Modeli XGBoost dla BTC i ETH

Tworzenie i trening modeli XGBoost (Extreme Gradient Boosting): Modele XGBoost zostały stworzone dla danych szeregów czasowych cen zamknięcia 'close' kryptowalut Bitcoin (BTC) i Ethereum (ETH), które następnie zostaną wykorzystane przy tworzeniu modeli predykcyjnych.

Cel:

- **Stworzenie i wytrenowanie modeli XGBoost:** Modele XGBoost pozwalają na analizę danych historycznych w formie sekwencji czasowych oraz dokładniejsze przewidywanie przyszłych wartości.

Proces:

- **Definicja modelu XGBoost:**
 - Utworzenie modelu jako instancji klasy XGBRegressor, z określonym celem regresji (`objective='reg:squarederror'`) oraz losowym seedem ustawionym na wartość 42 (`random_state=42`), co zapewnia powtarzalność wyników.
- **Przygotowanie danych treningowych:**
 - Dane wejściowe są przygotowane w formie sekwencji danych z przesuwającym się oknem czasowym (`sliding window`).
 - W każdym kroku tworzona jest sekwencja `look_back` kolejnych wartości historycznych, która stanowi dane wejściowe (`X`), oraz wartość następująca bezpośrednio po tej sekwencji jako wartość docelowa (`y`).
 - Każda sekwencja jest ręcznie spłaszczona za pomocą metody `.flatten()`, a następnie przekształcona w tablice NumPy, co umożliwia ich przetwarzanie przez model XGBoost.
- **Trenowanie modeli:**

- Modele zostały wytrenowane oddzielnie dla każdej kryptowaluty:
 - * `btc_xgb_model` dla danych Bitcoin (BTC).
 - * `eth_xgb_model` dla danych Ethereum (ETH).
- Funkcja `fit` modelu XGBoost została wykorzystana do dopasowania danych wejściowych (X) i wartości docelowych (y).

Korzyści:

- **Wydajność i skalowalność:** Algorytm XGBoost jest zoptymalizowany pod kątem efektywnego wykorzystania zasobów obliczeniowych, co czyni go idealnym dla dużych zbiorów danych.
- **Precyzyjne przewidywania:** Wykorzystanie danych historycznych w formie sekwencji pozwala modelowi XGBoost dokładnie odwzorowywać trendy w danych.
- **Elastyczność:** Model XGBoost jest elastyczny i może być łatwo dostosowany do różnych typów danych oraz zadań regresyjnych.

Podsumowanie: Budowa i trening modeli XGBoost dla przewidywania wartości zamknięcia kryptowalut BTC i ETH to istotny krok w procesie analizy predykcyjnej danych szeregów czasowych. Dzięki zastosowaniu algorytmu XGBoost możliwe jest uzyskanie dokładnych i wydajnych prognoz dla obu kryptowalut.

11 Ocena Modeli

Proces oceny modeli predykcyjnych został przeprowadzony na podstawie trzech miar: średniego błędu kwadratowego (MSE), średniego błędu bezwzględnego (MAE) oraz współczynnika determinacji (R^2). Miary te pozwoliły na określenie najbardziej wydajnego modelu.

Cel:

- Wybranie najbardziej wydajnego modelu, który najlepiej radzi sobie z predykcją cen zamknięcia obu kryptowalut.
- Ocena skuteczności pozostałych modeli w przewidywaniu wartości zamknięcia kryptowalut na podstawie danych historycznych.

Proces:

• Funkcja oceny modeli:

- Do oceny modeli wykorzystano funkcję `evaluate_model`. Przyjmuje ona jako argumenty model, generator danych (`gen`), skalery (używane do normalizacji danych), rzeczywiste dane (`actual_scaled`) oraz typ modelu (`model_type`).
- Modele dzielą się na dwie grupy:
 - * **Modele neuronowe** (LSTM, RNN, GRU, CNN): Prognozy generowane są poprzez metodę `predict` bezpośrednio na generatorze danych.

- * **Modele drzewiaste** (LightGBM, XGBoost): Wymagają przekształcenia danych wejściowych w postaci sliding window, spłaszczenia za pomocą metody `.flatten()` i przekształcenia w tablice NumPy.
- Dane prognozowane i rzeczywiste zostały przeskalowane do oryginalnej skali przy użyciu funkcji `inverse_transform`, co umożliwia ich dokładne porównanie.

- **Miary oceny:**

- **MSE:** Średni błąd kwadratowy, mierzący średnią różnicę kwadratów między wartościami rzeczywistymi a prognozowanymi.
- **MAE:** Średni błąd bezwzględny, mierzący średnią różnicę wartości absolutnych między wartościami rzeczywistymi a prognozowanymi.
- R^2 : Współczynnik determinacji, mierzący, jaka część wariancji wartości rzeczywistych jest uchwycona przez model.

- **Wyniki ewaluacji:**

Ticker	Model	MSE	MAE	R2
BTC	LSTM	2882393.0121	881.9757	0.9928
ETH	LSTM	13104.1657	76.5050	0.9912
BTC	RNN	1609974.1506	999.0382	0.9960
ETH	RNN	16396.6063	96.7982	0.9890
BTC	GRU	1701414.0788	810.5854	0.9957
ETH	GRU	8665.0010	59.8653	0.9942
BTC	CNN	2430758.7140	896.2413	0.9939
ETH	CNN	11101.1074	70.1349	0.9925
BTC	LightGBM	306545.9506	260.1958	0.9992
ETH	LightGBM	1859.0597	23.7673	0.9988
BTC	XGBoost	65870.6694	124.5931	0.9998
ETH	XGBoost	269.8971	10.2501	0.9998

Tabela 1: Porównanie wyników modeli dla BTC i ETH

- **Modele neuronowe:**

- * **LSTM:** Model osiągnął bardzo wysokie wartości R^2 dla obu kryptowalut, BTC (0.9931) i ETH (0.9896). Wskazuje to na zdolność modelu do dokładnego odwzorowania trendów w danych. Miary MSE (2733116.4466 dla BTC, 15504.0332 dla ETH) i MAE (960.1037 dla BTC, 76.5762 dla ETH) wskazują na umiarkowaną dokładność modelu.
- * **GRU:** Model przewyższył LSTM pod względem dokładności, osiągając R^2 wynoszące 0.9969 dla BTC i 0.9937 dla ETH. Niższe wartości MSE (1218998.9843 dla BTC, 9305.0182 dla ETH) i MAE (618.4487 dla BTC, 73.3603 dla ETH) wskazują na lepsze odwzorowanie danych.

- * **CNN:** Wyniki modelu są porównywalne do LSTM, z MSE (2762167.4991 dla BTC, 22718.9823 dla ETH), MAE (956.5446 dla BTC, 98.5123 dla ETH) oraz R^2 wynoszącym 0.9931 dla BTC i 0.9847 dla ETH.
- * **RNN:** Model osiągnął najniższe R^2 dla BTC (0.9535), co wskazuje na niższą skuteczność. Miary MSE (18502491.8040 dla BTC, 6516.4826 dla ETH) i MAE (2391.9861 dla BTC, 47.9561 dla ETH) również wskazują na mniejszą dokładność w porównaniu do innych modeli.

– **Modele drzewiaste:**

- * **LightGBM:** Model wykazał się wysoką precyzją, osiągając R^2 wynoszące 0.9992 dla BTC i 0.9988 dla ETH. Niskie wartości MSE (306545.9506 dla BTC, 1859.0597 dla ETH) i MAE (260.1958 dla BTC, 23.7673 dla ETH) wskazują na doskonałe odwzorowanie danych.
- * **XGBoost:** Model przewyższył wszystkie inne podejścia, osiągając R^2 wynoszące 0.9998 dla obu kryptowalut. Najniższe wartości MSE (65870.6694 dla BTC, 269.8971 dla ETH) i MAE (124.5931 dla BTC, 10.2501 dla ETH) wskazują na doskonałe odwzorowanie danych.

Podsumowanie:

- Model **XGBoost** został oceniony jako najskuteczniejszy w przewidywaniu cen zamknięcia kryptowalut BTC i ETH, osiągając najwyższe współczynniki R^2 oraz najniższe wartości MSE i MAE.
- **LightGBM** również wykazał się wysoką dokładnością, stanowiąc wartościową alternatywę.
- Wśród modeli neuronowych najlepsze wyniki uzyskały **GRU** i **LSTM**, co czyni je solidnymi narzędziami do analizy danych szeregów czasowych.

12 Wizualizacje Wyników Modeli

12.1 Wykres Liniowy Rzeczywistych i Przewidywanych Cen Zamknięcia dla BTC i ETH


Wizualizacja dokładności przewidywań dla modeli: Przeprowadzono wizualizację rzeczywistych i prognozowanych wartości cen zamknięcia dla kryptowalut Bitcoin (BTC) i Ethereum (ETH). Wykresy umożliwiają porównanie jakości dopasowania modeli oraz ich zdolności do odwzorowywania trendów i zmienności danych historycznych.

Cele wizualizacji:


- Ocena jakości dopasowania modeli poprzez porównanie przewidywań z rzeczywistymi wartościami cen zamknięcia.
- Analiza zdolności modeli do odwzorowywania trendów oraz reagowania na zmienność danych historycznych.

Wykresy dla BTC i ETH:

- **Model LSTM:** Wykazuje dobrą zgodność pomiędzy wartościami rzeczywistymi i prognozowanymi, szczególnie w przypadku długoterminowych trendów. Występują niewielkie różnice w okresach dynamicznych skoków cenowych.




Rysunek 21: Wykres Liniowy Rzeczywistych i Przewidywanych Cen Zamknięcia BTC dla modelu LSTM




Rysunek 22: Wykres Liniowy Rzeczywistych i Przewidywanych Cen Zamknięcia ETH dla modelu LSTM

- **Model RNN:** RNN mniej skutecznie odwzorowuje ceny zamknięcia w porównaniu z innymi modelami. Odchylenia są szczególnie widoczne dla aktywa BTC.




Rysunek 23: Wykres Liniowy Rzeczywistych i Przewidywanych Cen Zamknięcia BTC dla modelu RNN




Rysunek 24: Wykres Liniowy Rzeczywistych i Przewidywanych Cen Zamknięcia ETH dla modelu RNN

- **Model CNN:** Model dobrze radzi sobie z odwzorowywaniem trendów historycznych, jednak w okresach wysokiej zmienności napotyka trudności z dokładnym przewidywaniem dynamicznych zmian cen.




Rysunek 25: Wykres Liniowy Rzeczywistych i Przewidywanych Cen Zamknięcia BTC dla modelu CNN




Rysunek 26: Wykres Liniowy Rzeczywistych i Przewidywanych Cen Zamknięcia ETH dla modelu CNN

- **Model GRU:** GRU osiąga wyniki zbliżone do modelu LSTM, charakteryzując się bardzo dobrą zgodnością dla obu kryptowalut i mniejszymi różnicami w porównaniu do modeli takich jak CNN czy RNN.



Rysunek 27: Wykres Liniowy Rzeczywistych i Przewidywanych Cen Zamknięcia BTC dla modelu GRU




Rysunek 28: Wykres Liniowy Rzeczywistych i Przewidywanych Cen Zamknięcia ETH dla modelu GRU

- **Model LightGBM:** LightGBM dokładnie odwzorowuje zmiany w cenach zamknięcia i niemal idealnie dopasowuje się do rzeczywistych wartości.




Rysunek 29: Wykres Liniowy Rzeczywistych i Przewidywanych Cen Zamknięcia BTC dla modelu LightGBM




Rysunek 30: Wykres Liniowy Rzeczywistych i Przewidywanych Cen Zamknięcia ETH dla modelu LightGBM

- **Model XGBoost:** XGBoost wykazuje najwyższą zgodność z rzeczywistymi wartościami spośród wszystkich badanych modeli. Bardzo precyzyjnie odwzorowuje trendy i wahania cen dla obu kryptowalut.



Rysunek 31: Wykres Liniowy Rzeczywistych i Przewidywanych Cen Zamknięcia BTC dla modelu XGBoost



Rysunek 32: Wykres Liniowy Rzeczywistych i Przewidywanych Cen Zamknięcia ETH dla modelu XGBoost

Wnioski:

- **Zgodność modeli:** Modele XGBoost i LightGBM cechują się największą precyzją w przewidywaniu cen zamknięcia, co potwierdzają wizualizacje przedstawiające minimalne różnice pomiędzy wartościami rzeczywistymi i prognozowanymi.
- **Modele neuronowe:** GRU i LSTM osiągnęły wysoką zgodność, szczególnie w przypadku długoterminowych trendów. Jednak w okresach wysokiej zmienności obserwuje się większe odchylenia.
- **Różnice w modelach:** CNN i RNN wykazują większe różnice pomiędzy wartościami rzeczywistymi i prognozowanymi, szczególnie w przypadku BTC.
- **Zmienność aktywów:** Wyższa zmienność BTC w porównaniu z ETH była większym wyzwaniem dla modeli, co jest szczególnie widoczne na wykresach dla RNN i CNN.

Podsumowanie: Wizualizacje wyników predykcji cen zamknięcia dostarczają istotnych informacji o zdolnościach modeli do odwzorowywania danych szeregów czasowych. Modele XGBoost i LightGBM wykazały się najwyższą precyzją, co czyni je odpowiednimi do przyszłych analiz predykcyjnych.

12.2 Wykres Reszt dla Przewidywanych Cen Zamknięcia dla BTC i ETH


Wizualizacja reszt predykcji: Wizualizacja reszt predykcji umożliwia ocenę, jak dobrze analizowane modele radzą sobie z przewidywaniem cen zamknięcia kryptowalut BTC i ETH. Reszty są różnicą między wartościami rzeczywistymi a prognozowanymi. Dzięki nim możemy określić dokładność modeli oraz ich zdolność do przewidywania zmienności i trendów danych historycznych. Analiza reszt umożliwia zidentyfikowanie wzorców oraz ewentualnych problemów w zbudowanych modelach predykcyjnych.

Cele wizualizacji:


- Określenie poziomu błędów modeli predykcyjnych.
- Ocena odchyłeń i wzorców, które mogą wskazywać na ograniczenia modeli.

Wykresy reszt cen zamknięcia dla BTC i ETH:

- **Model LSTM:** Reszty dla modelu LSTM sugerują umiarkowany poziom błędów. Błędy są większe w okresach dynamicznych zmian cen zamknięcia. Model radzi sobie lepiej z przewidywaniem trendów długoterminowych. W przypadku gwałtownych wahań cen zamknięcia, wartości reszt rosną.




Rysunek 33: Wykres Reszt dla Przewidywanych Cen Zamknięcia dla BTC dla modelu LSTM




Rysunek 34: Wykres Reszt dla Przewidywanych Cen Zamknięcia dla ETH dla modelu LSTM

- **Model RNN:** Na podstawie wykresu reszt dla modelu RNN jesteśmy w stanie odczytać, że reszty dla tego modelu są bardziej rozproszone - wskazuje to na większe błędy w porównaniu do LSTM. Szczególnie wysokie są wartości reszt dla BTC, co świadczy o tym, że model ma trudności w odwzorowywaniu zmienności tego aktywa.




Rysunek 35: Wykres Reszt dla Przewidywanych Cen Zamknięcia dla BTC dla modelu RNN




Rysunek 36: Wykres Reszt dla Przewidywanych Cen Zamknięcia dla ETH dla modelu RNN

- **Model CNN:** Reszty dla modelu CNN są bardziej równomiernie rozłożone w porównaniu do RNN, jednak nadal odchylenia dla tego modelu są większe w okresach dużej zmienności cen. Wartości reszt dla ETH są znacznie mniejsze niż dla BTC.




Rysunek 37: Wykres Reszt dla Przewidywanych Cen Zamknięcia dla BTC dla modelu CNN




Rysunek 38: Wykres Reszt dla Przewidywanych Cen Zamknięcia dla ETH dla modelu CNN

- **Model GRU:** Na podstawie wizualizacji reszt dla modelu GRU można stwierdzić, że reszty dla tego modelu są zbliżone do tych z LSTM. Wykres dla modelu GRU cechuje się mniejszymi błędami w okresach stabilnych cen - w okresach dynamicznych skoków wartości reszty są bardziej rozproszone - co oznacza, że model ma trudności z odwzorowywaniem dużych zmian.




Rysunek 39: Wykres Reszt dla Przewidywanych Cen Zamknięcia dla BTC dla modelu GRU




Rysunek 40: Wykres Reszt dla Przewidywanych Cen Zamknięcia dla ETH dla modelu GRU

- **Model LightGBM:** Reszty dla LightGBM są najbardziej równomierne, a zaobserwowane błędy są minimalne. Świadczy to o wysokiej skuteczności tego modelu w odwzorowywaniu cen zamknięcia dla obu aktywów.




Rysunek 41: Wykres Reszt dla Przewidywanych Cen Zamknięcia dla BTC dla modelu LightGBM




Rysunek 42: Wykres Reszt dla Przewidywanych Cen Zamknięcia dla ETH dla modelu LightGBM

- **Model XGBoost:** Reszty modelu XGBoost są najbliżej osi zero w porównaniu do innych modeli - wartości reszt są minimalne, co wskazuje na precyzyjne odwzorowanie cen zamknięcia (zarówno w dynamicznych, jak i stabilnych okresach).



Rysunek 43: Wykres Reszt dla Przewidywanych Cen Zamknięcia dla BTC dla modelu XGBoost



Rysunek 44: Wykres Reszt dla Przewidywanych Cen Zamknięcia dla ETH dla modelu XGBoost

Wnioski:

- **Różnice w modelach:** Wizualizacje dla modeli XGBoost i LightGBM cechują się najmniejszym rozproszeniem reszt, co świadczy o ich precyzji. Dobre wyniki osiągnęły również modele neuronowe (LSTM, GRU), ale mimo wszystko w okresach wysokiej zmienności zaobserwowano dla nich błędy.
- **Wpływ zmienności:** Większym wyzwaniem dla wszystkich modeli jest kryptowaluta BTC (jako bardziej zmienne aktywo). Ethereum cechuje się mniejszymi resztami, co sugeruje bardziej przewidywalny charakter tego aktywa.

Podsumowanie: Wizualizacje reszt pomagają określić, które modele najlepiej radzą sobie z predykcją cen zamknięcia oraz w jakich warunkach występują największe błędy w ich przewidywaniu. Analiza ta jest istotna przy wyborze modelu do przyszłych analiz predykcyjnych.

12.3 Wykres Rozkładu Błędów Predykcji Cen Zamknięcia dla BTC i ETH


Wizualizacja rozkładu błędów predykcji: Wizualizacja rozkładu błędów predykcji pozwala ocenić dokładność i precyzję wybranych modeli predykcyjnych. Rozkład błędów, czyli różnica między wartościami rzeczywistymi a prognozowanymi, umożliwia również identyfikację ewentualnych problemów z przewidywaniem cen aktywów BTC i ETH. Wykresy te pozwalają lepiej zrozumieć ograniczenia modeli oraz ich zdolność do przewidywania zmienności i trendów w danych historycznych.

Cele wizualizacji:


- Ocena precyzji modeli predykcyjnych.
- Identyfikacja potencjalnych odchyleń w modelach.
- Zrozumienie różnic w skuteczności modeli dla aktywów BTC i ETH.

Rozkłady błędów dla modeli predykcyjnych:

- **Model LSTM:** Rozkłady błędów dla modelu LSTM sugerują umiarkowaną dokładność tego modelu. Błędy są szczególnie znaczące w okresach dynamicznych zmian cen zamknięcia, co oznacza, że model radzi sobie lepiej podczas stabilnych warunków rynkowych. Dla aktywa BTC rozproszenie błędów jest większe niż dla ETH.




Rysunek 45: Wykres Rozkładu Błędów Predykcji Cen Zamknięcia dla BTC dla modelu LSTM




Rysunek 46: Wykres Rozkładu Błędów Predykcji Cen Zamknięcia dla ETH dla modelu LSTM

- **Model RNN:** Rozkład błędów modelu RNN cechuje się większym odchyleniem w porównaniu do modelu LSTM. Szczególnie dla BTC błędy są bardziej rozproszone, co wskazuje na trudności modelu w odwzorowywaniu zmienności tego aktywa. ETH charakteryzuje się bardziej symetrycznym rozkładem błędów.




Rysunek 47: Wykres Rozkładu Błędów Predykcji Cen Zamknięcia dla BTC dla modelu RNN




Rysunek 48: Wykres Rozkładu Błędów Predykcji Cen Zamknięcia dla ETH dla modelu RNN

- **Model CNN:** Rozkłady błędów modelu CNN są bardziej skoncentrowane wokół zera w porównaniu do RNN. Dla ETH błędy są stosunkowo niewielkie, natomiast dla BTC w okresach dużej zmienności są one znaczne.




Rysunek 49: Wykres Rozkładu Błędów Predykcji Cen Zamknięcia dla BTC dla modelu CNN




Rysunek 50: Wykres Rozkładu Błędów Predykcji Cen Zamknięcia dla ETH dla modelu CNN

- **Model GRU:** Model GRU charakteryzuje się rozkładem błędów zbliżonym do LSTM. Błędy są mniejsze w stabilnych warunkach rynkowych, jednak dla BTC w okresach dynamicznych zmian rozproszenie błędów jest większe.




Rysunek 51: Wykres Rozkładu Błędów Predykcji Cen Zamknięcia dla BTC dla modelu GRU




Rysunek 52: Wykres Rozkładu Błędów Predykcji Cen Zamknięcia dla ETH dla modelu GRU

- **Model LightGBM:** Rozkład błędów dla modelu LightGBM wskazuje na minimalne błędy zarówno dla BTC, jak i ETH, co świadczy o wysokiej skuteczności modelu w przewidywaniu cen zamknięcia.




Rysunek 53: Wykres Rozkładu Błędów Predykcji Cen Zamknięcia dla BTC dla modelu LightGBM




Rysunek 54: Wykres Rozkładu Błędów Predykcji Cen Zamknięcia dla ETH dla modelu LightGBM

- **Model XGBoost:** Rozkład błędów dla modelu XGBoost cechuje się największą koncentracją wokół zera spośród wszystkich modeli. Błędy są minimalne zarówno dla BTC, jak i ETH.



Rysunek 55: Wykres Rozkładu Błędów Predykcji Cen Zamknięcia dla BTC dla modelu XGBoost



Rysunek 56: Wykres Rozkładu Błędów Predykcji Cen Zamknięcia dla ETH dla modelu XGBoost

Wnioski:

- **Różnice w modelach:** Modele XGBoost i LightGBM cechują się największą dokładnością i najmniejszymi błędami. Modele neuronowe, takie jak LSTM i GRU, lepiej radzą sobie w stabilnych warunkach rynkowych.
- **Wpływ zmienności:** BTC, jako bardziej zmienne aktywo, stanowi większe wyzwanie dla modeli niż ETH, które jest bardziej przewidywalne.

Podsumowanie: Wizualizacja rozkładu błędów pozwala na głębszą analizę skuteczności modeli i pomaga wybrać najlepszy model do przewidywania cen zamknięcia kryptowalut.

12.4 Wykres Rozrzutu Rzeczywistych i Przewidywanych Cen Zamknięcia dla BTC i ETH


Wizualizacja wyników rozrzutu rzeczywistych i przewidywanych cen zamknięcia: Wizualizacja wyników rozrzutu rzeczywistych i przewidywanych cen zamknięcia kryptowalut BTC i ETH poprzez porównanie wartości rzeczywistych i prognozowanych pozwala na ocenę dopasowania modeli. Na wykresach porównane są rzeczywiste wartości historycznych cen zamknięcia z przewidywanymi. Dzięki temu możliwa jest analiza zdolności modeli do precyzyjnego odwzorowywania trendów historycznych i zmienności rynku.

Cele wizualizacji:


- Porównanie rzeczywistych wartości cen zamknięcia z prognozowanymi przez modele.
- Ocena skuteczności modeli w odwzorowywaniu trendów i zmienności danych.
- Identyfikacja różnic w działaniu modeli dla aktywów BTC i ETH.

Wyniki dla modeli predykcyjnych:

- **Model LSTM:** Wyniki modelu LSTM wskazują na dobrą zgodność pomiędzy rzeczywistymi i przewidywanymi wartościami. Model skutecznie odwzorowuje długoterminowe trendy, ale przy dynamicznych zmianach cen zamknięcia występują większe odchylenia, szczególnie dla BTC.




Rysunek 57: Wykres Rozrzutu Rzeczywistych i Przewidywanych Cen Zamknięcia dla BTC dla modelu LSTM




Rysunek 58: Wykres Rozrzutu Rzeczywistych i Przewidywanych Cen Zamknięcia dla ETH dla modelu LSTM

- **Model RNN:** Model RNN radzi sobie słabiej w odwzorowywaniu wartości rzeczywistych, zwłaszcza dla BTC, gdzie widoczne są większe rozbieżności. ETH, jako bardziej stabilne aktywo, jest odwzorowywane lepiej.




Rysunek 59: Wykres Rozrzutu Rzeczywistych i Przewidywanych Cen Zamknięcia dla BTC dla modelu RNN




Rysunek 60: Wykres Rozrzutu Rzeczywistych i Przewidywanych Cen Zamknięcia dla ETH dla modelu RNN

- **Model GRU:** Model GRU osiąga wyniki zbliżone do LSTM, z wysoką zgodnością w okresach stabilnych cen. Odchylenia w dynamicznych okresach są większe dla BTC, podczas gdy ETH charakteryzuje się wysoką zgodnością.




Rysunek 61: Wykres Rozrzutu Rzeczywistych i Przewidywanych Cen Zamknięcia dla BTC dla modelu GRU




Rysunek 62: Wykres Rozrzutu Rzeczywistych i Przewidywanych Cen Zamknięcia dla ETH dla modelu GRU

- **Model CNN:** Model CNN radzi sobie dobrze z długoterminowymi trendami, ale ma trudności w dokładnym odwzorowywaniu dynamicznych skoków cen (szczególnie dla BTC). ETH odwzorowane jest z mniejszymi różnicami między rzeczywistymi a prognozowanymi wartościami.




Rysunek 63: Wykres Rozrzutu Rzeczywistych i Przewidywanych Cen Zamknięcia dla BTC dla modelu CNN




Rysunek 64: Wykres Rozrzutu Rzeczywistych i Przewidywanych Cen Zamknięcia dla ETH dla modelu CNN

- **Model LightGBM:** Model LightGBM osiąga bardzo wysoką precyzję, co jest zilustrowane na wykresach dla obu kryptowalut - zarówno BTC, jak i ETH są odwzorowywane z bardzo małymi odchyleniami. Wskazuje to doskonałą zdolność modelu do odwzorowywania rzeczywistych cen.




Rysunek 65: Wykres Rozrzutu Rzeczywistych i Przewidywanych Cen Zamknięcia dla BTC dla modelu LightGBM




Rysunek 66: Wykres Rozrzutu Rzeczywistych i Przewidywanych Cen Zamknięcia dla ETH dla modelu LightGBM

- **Model XGBoost:** Model XGBoost charakteryzuje się najwyższą zgodnością pomiędzy rzeczywistymi a przewidywanymi wartościami. Wykresy pokazują niemal idealne dopasowanie dla obu kryptowalut, co czyni ten model najbardziej dokładnym w tej analizie.



Rysunek 67: Wykres Rozrzutu Rzeczywistych i Przewidywanych Cen Zamknięcia dla BTC dla modelu XGBoost



Rysunek 68: Wykres Rozrzutu Rzeczywistych i Przewidywanych Cen Zamknięcia dla ETH dla modelu XGBoost

Wnioski:

- **Najlepsze modele:** Modele XGBoost i LightGBM wykazują się najwyższą dokładnością w odwzorowywaniu rzeczywistych cen zamknięcia zarówno dla BTC, jak i ETH.
- **Modele neuronowe:** Modele LSTM i GRU osiągnęły dobrą dokładność, szczególnie w okresach stabilnych rynków. Mają one jednak trudności w odwzorowywaniu dynamicznych zmian cen.
- **Modele CNN i RNN:** Te modele osiągnęły najniższą skuteczność, szczególnie w przypadku bardziej zmiennego BTC.
- **Zmienność aktywów:** BTC, jako bardziej zmienne aktywo, stanowiło większe wyzwanie dla badanych modeli w porównaniu do ETH.

Podsumowanie: Wizualizacja wyników predykcji modeli oraz wartości rzeczywistych historycznych cen zamknięcia dostarcza cennych informacji dotyczących dokładności modeli i pomaga wskazać te, które najlepiej nadają się do dalszych analiz predykcyjnych.

12.5 Wykres Skumulowanych Stóp Zwrotu Rzeczywistych i Przewidywanych Cen Zamknięcia dla BTC i ETH


Wizualizacja skumulowanych stóp zwrotów rzeczywistych i przewidywanych cen zamknięcia: Wizualizacja skumulowanych zwrotów kryptowalut BTC i ETH na podstawie rzeczywistych i przewidywanych wartości cen zamknięcia pozwala ocenić zdolność modeli predykcyjnych do odwzorowywania ogólnych trendów wzrostu i spadku wartości inwestycji. Analiza tych wykresów umożliwia zidentyfikowanie, jak modele radzą sobie w długo- i krótkoterminowym odwzorowywaniu skumulowanych zwrotów.

Cele wizualizacji:


- Porównanie rzeczywistych i prognozowanych skumulowanych zwrotów.
- Ocena dokładności modeli w odwzorowywaniu trendów długoterminowych.
- Identyfikacja różnic między modelami w prognozowaniu zwrotów na dynamicznym rynku kryptowalut.
- Zrozumienie wpływu zmienności aktyw BTC i ETH na skuteczność modeli.

Wyniki dla modeli predykcyjnych:

- **Model LSTM:** Wyniki modelu LSTM ukazują dobrą zgodność między rzeczywistymi a prognozowanymi skumulowanymi zwrotami, szczególnie w okresach stabilnych rynków. Dla BTC w dynamicznych okresach odnotowano większe różnice, podczas gdy ETH charakteryzuje się lepszą dokładnością modelu.




Rysunek 69: Wykres Skumulowanych Stóp Zwrotu Rzeczywistych i Przewidywanych Cen Zamknięcia dla BTC dla modelu LSTM




Rysunek 70: Wykres Skumulowanych Stóp Zwrotu Rzeczywistych i Przewidywanych Cen Zamknięcia dla ETH dla modelu LSTM

- **Model RNN:** Model RNN prezentuje umiarkowaną dokładność w odwzorowywaniu skumulowanych zwrotów. Większe różnice występują dla bardziej zmiennego BTC, natomiast ETH, jako bardziej stabilne aktywo, jest odwzorowywane lepiej.




Rysunek 71: Wykres Skumulowanych Stóp Zwrotu Rzeczywistych i Przewidywanych Cen Zamknięcia dla BTC dla modelu RNN




Rysunek 72: Wykres Skumulowanych Stóp Zwrotu Rzeczywistych i Przewidywanych Cen Zamknięcia dla ETH dla modelu RNN

- **Model GRU:** Wyniki modelu GRU wskazują na dobrą zgodność w okresach stabilnych rynków. BTC charakteryzuje się większymi odchyleniami w porównaniu do ETH, które jest odwzorowywane z większą precyzją.




Rysunek 73: Wykres Skumulowanych Stóp Zwrotu Rzeczywistych i Przewidywanych Cen Zamknięcia dla BTC dla modelu GRU




Rysunek 74: Wykres Skumulowanych Stóp Zwrotu Rzeczywistych i Przewidywanych Cen Zamknięcia dla ETH dla modelu GRU

- **Model CNN:** Model CNN wykazuje się dużą zdolnością do odwzorowywania trendów długoterminowych. Jednak ma trudności z dokładnym odwzorowywaniem dynamicznych zmian zwrotów, szczególnie dla BTC. ETH jest odwzorowane z mniejszymi odchyleniami.




Rysunek 75: Wykres Skumulowanych Stóp Zwrotu Rzeczywistych i Przewidywanych Cen Zamknięcia dla BTC dla modelu CNN




Rysunek 76: Wykres Skumulowanych Stóp Zwrotu Rzeczywistych i Przewidywanych Cen Zamknięcia dla ETH dla modelu CNN

- **Model LightGBM:** LightGBM wyróżnia się wysoką dokładnością w prognozowaniu skumulowanych zwrotów zarówno dla BTC, jak i ETH. Wykresy wskazują na minimalne różnice między wartościami rzeczywistymi a prognozowanymi.




Rysunek 77: Wykres Skumulowanych Stóp Zwrotu Rzeczywistych i Przewidywanych Cen Zamknięcia dla BTC dla modelu LightGBM




Rysunek 78: Wykres Skumulowanych Stóp Zwrotu Rzeczywistych i Przewidywanych Cen Zamknięcia dla ETH dla modelu LightGBM

- **Model XGBoost:** Model XGBoost osiągnął najlepszą zgodność między rzeczywistymi a prognozowanymi skumulowanymi zwrotami. Wykresy wskazują niemal idealne dopasowanie dla obu kryptowalut.



Rysunek 79: Wykres Skumulowanych Stóp Zwrotu Rzeczywistych i Przewidywanych Cen Zamknięcia dla BTC dla modelu XGBoost



Rysunek 80: Wykres Skumulowanych Stóp Zwrotu Rzeczywistych i Przewidywanych Cen Zamknięcia dla ETH dla modelu XGBoost

Wnioski:

- **Najlepsze modele:** XGBoost i LightGBM wykazały najwyższą skuteczność w prognozowaniu skumulowanych zwrotów.
- **Modele neuronowe:** LSTM i GRU cechują się dobrą dokładnością w stabilnych warunkach rynkowych, ale trudności pojawiają się w dynamicznych okresach.
- **Modele CNN i RNN:** Te modele osiągnęły najslabsze wyniki, zwłaszcza w przypadku bardziej zmiennego BTC.
- **Zmienność aktywów:** BTC, jako bardziej zmienne aktywo, było większym wyzwaniem dla modeli w porównaniu do bardziej stabilnego ETH.

Podsumowanie: Wizualizacja skumulowanych zwrotów dostarcza cennych informacji o możliwościach modeli w prognozowaniu długoterminowych trendów inwestycyjnych na dynamicznym rynku kryptowalut.

13 Dashboard

13.1 Zapis wyników do plików CSV

W celu użycia danych w programie Power BI wyniki uzyskane dla obu kryptowalut (Bitcoin i Ethereum) oraz wszystkich testowanych modeli predykcyjnych są zapisywane w plikach CSV. Obejęte zapisem są wartości rzeczywiste, prognozowane, reszty, rozkład błędów oraz wskaźniki oceny jakości modeli (MSE, MAE, R^2). W celu zapisu danych wykorzystano funkcje zapisujące różne aspekty wyników w osobnych plikach CSV. Dzięki temu jesteśmy w stanie wykorzystać je później w interaktywnym dashboardzie. Każda funkcja działa poprzez iteracyjne porównanie wartości rzeczywistych z prognozowanymi, obliczanie błędów i reszt i innych miar a następnie zapis wyników w odpowiednim formacie. Ta struktura pozwala na przejrzystą analizę i dalsze wykorzystanie wyników w analizie wizualnej.

13.2 Funkcjonalności Dashboardu

Dasboard wizualizuje analizę i wyniki modeli predykcyjnych dla cen zamknięcia kryptowalut (Bitcoin i Ethereum). Zaprezentowane są kluczowe wskaźniki i porównania.

13.2.1 Tytuł

- Tytuł „**Bitcoin and Ethereum Price Prediction**” określający cel Dashboardu.

13.2.2 Tabelaryczne podsumowanie modeli

- Tabela po lewej stronie Dashboardu przedstawia wyniki modeli predykcyjnych (**LSTM**, **RNN**, **GRU**, **CNN**, **LightGBM**, **XGBoost**) wraz z ich wskaźnikami jakości:

- **MSE (Mean Squared Error)**,
 - **MAE (Mean Absolute Error)**,
 - **R² (współczynnik determinacji)**.
- Wartości są oddzielone dla kryptowalut.

13.2.3 Wykres kolumnowy

- Wykres po prawej stronie porównuje wskaźniki **MSE**, **MAE** i **R²** dla różnych modeli.
- Pomaga wizualnie ocenić, który model działa najlepiej i jaka jest skala wartości wskaźników oraz zależności między nimi.

13.2.4 Fragmentatory

- Użytkownik może filtrować dane według:
 - **Modelu**,
 - **Tickeru (BTC/ETH)**,
 - **Daty** (przedział czasowy do analizy szczegółowej).

13.2.5 Wykres Liniowy „Actual vs Predicted Price by Date”

- Dolny, lewy wykres liniowy przedstawia rzeczywiste i przewidywane ceny w czasie.
- Dzięki temu jesteśmy w stanie ocenić dokładność prognoz modelu dla wybranego okresu czasowego.

13.2.6 Wykres Liniowy „Residuals by Date”

- Dolny, prawy wykres liniowy ilustruje reszty, czyli różnice między wartościami rzeczywistymi a przewidywanymi w czasie.
- Pozwala ocenić, jak duże błędy popełnia model w różnych okresach.

14 Podsumowanie

Podsumowanie W ramach pracy zrealizowano projekt mający na celu opracowanie i porównanie modeli predykcyjnych do prognozowania cen zamknięcia (zmiennnej 'close') dwóch jednych z najbardziej popularnych kryptowalut – Bitcoina (BTC) i Ethereum (ETH). Głównym celem badania było znalezienie najlepszego modelu, czyli takiego, którego prognozy są najdokładniejsze przy uwzględnieniu różnorodności rynkowej oraz zmienności cen charakterystycznej dla rynku kryptowalut.

Zastosowane algorytmy obejmowały zarówno modele neuronowe, takie jak LSTM, RNN, GRU czy CNN, jak i modele maszynowego uczenia się - LightGBM i XGBoost. Ewaluacja ich skuteczności została przeprowadzona na podstawie kluczowych i popularnych miar, takich jak MSE, MAE i R2. Wyniki analizy wykazały, że modele

takie jak XGBoost i LightGBM cechują się wyższą precyzją w prognozowaniu cen zamknięcia, szczególnie w kontekście zmiennych warunków rynkowych, w porównaniu do bardziej złożonych modeli neuronowych takich jak RNN czy CNN.

Na koniec projektu zrealizowano interaktywny dashboard, który pozwala użytkownikom analizować wyniki predykcji w prosty sposób. Dashboard pozwala na wybór aktywa, modelu oraz przedziału czasowego. Generowane są interaktywne wykresy, które wspierają interpretację danych oraz wyników analizy. Dashboard, jako dodatkowy element pracy zwiększa jej praktyczną wartość - stanowi on praktyczne narzędzie, które może być wykorzystane w rzeczywistych scenariuszach inwestycyjnych.

Przeprowadzone badanie uwydatniło również ryzyka związane z predykcją kryptowalut poprzez uczenie maszynowe takie jak niestabilność tego rynku co zdecydowanie wpływało na jakość niektórych prognoz. Potencjalnym problemem mogło okazać się też nadmierne dopasowaniem (overfittingiem) modeli neuronowych, jednakże w tym projekcie zbiór danych został dobrze dopasowany do celu i zagadnienia, zatem problem nie wystąpił. Zidentyfikowanie tych ograniczeń stanowi punkt wyjścia dla kolejnych badań w kierunku doskonalenia algorytmów predykcyjnych dla cen zamknięcia ('close') kryptowalut.

Podsumowując, projekt udowodnił najwyższą skuteczność dla modelu XGBoost. Opracowana metodologia, wyniki oraz wdrożone narzędzia stanowią dobrą podstawę do dalszego rozwoju i zastosowań w obszarze analizy rynku kryptowalut.

15 Wykaz tabel

Spis tabel

1	Porównanie wyników modeli dla BTC i ETH	58
---	---	----

16 Wykaz rysunków

Spis rysunków

1	Histogram Cen Zamknięcia dla BTC	25
2	Histogram Cen Zamknięcia dla ETH	26
3	Wykres Pudełkowy Cen Zamknięcia dla BTC	27
4	Wykres Pudełkowy Cen Zamknięcia dla ETH	28
5	Wykres Liniowy Ceny Zamknięcia w Czasie dla BTC	29
6	Wykres Liniowy Ceny Zamknięcia w Czasie dla ETH	30
7	Wykres 30 Dniowej Średniej Kroczącej Cen Zamknięcia dla BTC . . .	31
8	Wykres 30 Dniowej Średniej Kroczącej Cen Zamknięcia dla ETH . . .	32
9	Wykres Liniowy Zmian Procentowych Cen Zamknięcia dla BTC . . .	33
10	Wykres Liniowy Zmian Procentowych Cen Zamknięcia dla ETH . . .	34
11	Wykres Gęstości Cen Zamknięcia dla BTC	35
12	Wykres Gęstości Cen Zamknięcia dla ETH	36
13	Mapa Korelacji Zmiennych Rynkowych dla BTC	37
14	Mapa Korelacji Zmiennych Rynkowych dla ETH	38
15	Wykres Autokorelacji dla BTC	40
16	Wykres Autokorelacji dla ETH	41
17	Wykres Trendu Czasowego Cen Zamknięcia dla BTC	43
18	Wykres Trendu Czasowego Cen Zamknięcia dla ETH	44
19	Wykres Reszt dla BTC	45
20	Wykres Reszt dla ETH	46
21	Wykres Liniowy Rzeczywistych i Przewidywanych Cen Zamknięcia BTC dla modelu LSTM	60
22	Wykres Liniowy Rzeczywistych i Przewidywanych Cen Zamknięcia ETH dla modelu LSTM	60
23	Wykres Liniowy Rzeczywistych i Przewidywanych Cen Zamknięcia BTC dla modelu RNN	61
24	Wykres Liniowy Rzeczywistych i Przewidywanych Cen Zamknięcia ETH dla modelu RNN	61
25	Wykres Liniowy Rzeczywistych i Przewidywanych Cen Zamknięcia BTC dla modelu CNN	62
26	Wykres Liniowy Rzeczywistych i Przewidywanych Cen Zamknięcia ETH dla modelu CNN	62
27	Wykres Liniowy Rzeczywistych i Przewidywanych Cen Zamknięcia BTC dla modelu GRU	63
28	Wykres Liniowy Rzeczywistych i Przewidywanych Cen Zamknięcia ETH dla modelu GRU	63

29	Wykres Liniowy Rzeczywistych i Przewidywanych Cen Zamknięcia BTC dla modelu LightGBM	64
30	Wykres Liniowy Rzeczywistych i Przewidywanych Cen Zamknięcia ETH dla modelu LightGBM	64
31	Wykres Liniowy Rzeczywistych i Przewidywanych Cen Zamknięcia BTC dla modelu XGBoost	65
32	Wykres Liniowy Rzeczywistych i Przewidywanych Cen Zamknięcia ETH dla modelu XGBoost	65
33	Wykres Reszt dla Przewidywanych Cen Zamknięcia dla BTC dla modelu LSTM	67
34	Wykres Reszt dla Przewidywanych Cen Zamknięcia dla ETH dla modelu LSTM	67
35	Wykres Reszt dla Przewidywanych Cen Zamknięcia dla BTC dla modelu RNN	68
36	Wykres Reszt dla Przewidywanych Cen Zamknięcia dla ETH dla modelu RNN	68
37	Wykres Reszt dla Przewidywanych Cen Zamknięcia dla BTC dla modelu CNN	69
38	Wykres Reszt dla Przewidywanych Cen Zamknięcia dla ETH dla modelu CNN	69
39	Wykres Reszt dla Przewidywanych Cen Zamknięcia dla BTC dla modelu GRU	70
40	Wykres Reszt dla Przewidywanych Cen Zamknięcia dla ETH dla modelu GRU	70
41	Wykres Reszt dla Przewidywanych Cen Zamknięcia dla BTC dla modelu LightGBM	71
42	Wykres Reszt dla Przewidywanych Cen Zamknięcia dla ETH dla modelu LightGBM	71
43	Wykres Reszt dla Przewidywanych Cen Zamknięcia dla BTC dla modelu XGBoost	72
44	Wykres Reszt dla Przewidywanych Cen Zamknięcia dla ETH dla modelu XGBoost	72
45	Wykres Rozkładu Błędów Predykcji Cen Zamknięcia dla BTC dla modelu LSTM	74
46	Wykres Rozkładu Błędów Predykcji Cen Zamknięcia dla ETH dla modelu LSTM	74
47	Wykres Rozkładu Błędów Predykcji Cen Zamknięcia dla BTC dla modelu RNN	75
48	Wykres Rozkładu Błędów Predykcji Cen Zamknięcia dla ETH dla modelu RNN	75
49	Wykres Rozkładu Błędów Predykcji Cen Zamknięcia dla BTC dla modelu CNN	76
50	Wykres Rozkładu Błędów Predykcji Cen Zamknięcia dla ETH dla modelu CNN	76
51	Wykres Rozkładu Błędów Predykcji Cen Zamknięcia dla BTC dla modelu GRU	77
52	Wykres Rozkładu Błędów Predykcji Cen Zamknięcia dla ETH dla modelu GRU	77

53	Wykres Rozkładu Błędów Predykcji Cen Zamknięcia dla BTC dla modelu LightGBM	78
54	Wykres Rozkładu Błędów Predykcji Cen Zamknięcia dla ETH dla modelu LightGBM	78
55	Wykres Rozkładu Błędów Predykcji Cen Zamknięcia dla BTC dla modelu XGBoost	79
56	Wykres Rozkładu Błędów Predykcji Cen Zamknięcia dla ETH dla modelu XGBoost	79
57	Wykres Rozrzutu Rzeczywistych i Przewidywanych Cen Zamknięcia dla BTC dla modelu LSTM	81
58	Wykres Rozrzutu Rzeczywistych i Przewidywanych Cen Zamknięcia dla ETH dla modelu LSTM	81
59	Wykres Rozrzutu Rzeczywistych i Przewidywanych Cen Zamknięcia dla BTC dla modelu RNN	82
60	Wykres Rozrzutu Rzeczywistych i Przewidywanych Cen Zamknięcia dla ETH dla modelu RNN	82
61	Wykres Rozrzutu Rzeczywistych i Przewidywanych Cen Zamknięcia dla BTC dla modelu GRU	83
62	Wykres Rozrzutu Rzeczywistych i Przewidywanych Cen Zamknięcia dla ETH dla modelu GRU	83
63	Wykres Rozrzutu Rzeczywistych i Przewidywanych Cen Zamknięcia dla BTC dla modelu CNN	84
64	Wykres Rozrzutu Rzeczywistych i Przewidywanych Cen Zamknięcia dla ETH dla modelu CNN	84
65	Wykres Rozrzutu Rzeczywistych i Przewidywanych Cen Zamknięcia dla BTC dla modelu LightGBM	85
66	Wykres Rozrzutu Rzeczywistych i Przewidywanych Cen Zamknięcia dla ETH dla modelu LightGBM	85
67	Wykres Rozrzutu Rzeczywistych i Przewidywanych Cen Zamknięcia dla BTC dla modelu XGBoost	86
68	Wykres Rozrzutu Rzeczywistych i Przewidywanych Cen Zamknięcia dla ETH dla modelu XGBoost	86
69	Wykres Skumulowanych Stóp Zwrotu Rzeczywistych i Przewidywanych Cen Zamknięcia dla BTC dla modelu LSTM	88
70	Wykres Skumulowanych Stóp Zwrotu Rzeczywistych i Przewidywanych Cen Zamknięcia dla ETH dla modelu LSTM	88
71	Wykres Skumulowanych Stóp Zwrotu Rzeczywistych i Przewidywanych Cen Zamknięcia dla BTC dla modelu RNN	89
72	Wykres Skumulowanych Stóp Zwrotu Rzeczywistych i Przewidywanych Cen Zamknięcia dla ETH dla modelu RNN	89
73	Wykres Skumulowanych Stóp Zwrotu Rzeczywistych i Przewidywanych Cen Zamknięcia dla BTC dla modelu GRU	90
74	Wykres Skumulowanych Stóp Zwrotu Rzeczywistych i Przewidywanych Cen Zamknięcia dla ETH dla modelu GRU	90
75	Wykres Skumulowanych Stóp Zwrotu Rzeczywistych i Przewidywanych Cen Zamknięcia dla BTC dla modelu CNN	91
76	Wykres Skumulowanych Stóp Zwrotu Rzeczywistych i Przewidywanych Cen Zamknięcia dla ETH dla modelu CNN	91

77	Wykres Skumulowanych Stóp Zwrotu Rzeczywistych i Przewidywanych Cen Zamknięcia dla BTC dla modelu LightGBM	92
78	Wykres Skumulowanych Stóp Zwrotu Rzeczywistych i Przewidywanych Cen Zamknięcia dla ETH dla modelu LightGBM	92
79	Wykres Skumulowanych Stóp Zwrotu Rzeczywistych i Przewidywanych Cen Zamknięcia dla BTC dla modelu XGBoost	93
80	Wykres Skumulowanych Stóp Zwrotu Rzeczywistych i Przewidywanych Cen Zamknięcia dla ETH dla modelu XGBoost	93

17 Bibliografia

- [1] Komunikat Ministra Finansów z dnia 5.01.2024 r. w sprawie ogłoszenia uchwały Komitetu Standardów Rachunkowości w sprawie przyjęcia Stanowiska Komitetu Standardów Rachunkowości w sprawie ustalania wartości godziwej dla potrzeb rozliczania połączeń jednostek metodą nabycia. Dz. Urz. Min. Fin. z 2024 r., poz. 23. Dostępne pod adresem: <https://przepisy.gofin.pl/przepisy,4,16,181,8193,,komunikat-ministra-finansow-z-dnia-5012024-r-w-sprawie.html>
- [2] Subramanian, J., & Simon, R. (2013). *Overfitting in Prediction Models - Is It a Problem Only In High Dimensions?*. Contemporary Clinical Trials, 36(2). DOI: 10.1016/j.cct.2013.06.011.
- [3] Liquet, B., Moka, S., & Nazarathy, Y. (2021). *The Mathematical Engineering of Deep Learning*, Rozdział 8: Sequence Models, s. 123. Dostępne pod adresem: <https://deeplearningmath.org/sequence-models>
- [4] Hochreiter, S., & Schmidhuber, J. (1997). *Long Short-Term Memory*. Neural Computation, 9(8), 1735–1780. Dostępne pod adresem: <https://direct.mit.edu/neco/article/9/8/1735/6109/Long-Short-Term-Memory>
- [5] Cho, K., Van Merriënboer, B., Gulcehre, C., Bahdanau, D., Bougares, F., Schwenk, H., & Bengio, Y. (2014). *Learning Phrase Representations using RNN Encoder–Decoder for Statistical Machine Translation*. arXiv preprint arXiv:1406.1078. Dostępne pod adresem: <https://arxiv.org/abs/1406.1078>
- [6] Gillis, A. S., Craig, L., & Awati, R. (2024). *What is a convolutional neural network (CNN)?*. Dostępne pod adresem: <https://www.techtarget.com/searchenterpriseai/definition/convolutional-neural-network>
- [7] IBM. (n.d.). *Decision tree models*. Dostępne pod adresem: <https://www.ibm.com/docs/pl/spss-modeler/saas?topic=trees-decision-tree-models>
- [8] Vaishnavi, Y. (n.d.). *Light GBM*. Dostępne pod adresem: <https://medium.com/@vaishnaviy502/light-gbm-c11e06b53479>
- [9] Chen, T., & Guestrin, C. (n.d.). *XGBoost Documentation*. Dostępne pod adresem: <https://xgboost.readthedocs.io/en/stable/>
- [10] Chugh, A. (2020). *MAE, MSE, RMSE, Coefficient of Determination, Adjusted R Squared — Which Metric is Better?*. Analytics Vidhya. Dostępne pod adresem: <https://medium.com/analytics-vidhya/mae-mse-rmse-coefficient-of-determination-adjusted-r-squared>
- [11] Chodynieski, P. (2025). *Czym jest kapitalizacja rynkowa kryptowalut i jak wpływa na inwestycje?*. Quark Blog. Dostępne pod adresem: <https://quark.house/blog/czym-jest-kapitalizacja-rynkowa-kryptowalut/>

- [12] CoinMarketCap Academy. *Glossary: Ticker Symbol*. Dostępne pod adresem: <https://coinmarketcap.com/academy/glossary/ticker-symbol>
- [13] CoinMarketCap Academy. *Glossary: Open/Close*. Dostępne pod adresem: <https://coinmarketcap.com/academy/glossary/open-close>
- [14] Bitget Academy. *Crypto Trading Terminology for Beginners: High/Low*. Dostępne pod adresem: <https://www.bitget.com/pl/academy/crypto-trading-terminology-for-beginners>
- [15] Drapala, J. (n.d.). *Kernel Density Estimator explained step by step*. Towards Data Science. Dostępne pod adresem: <https://towardsdatascience.com>
- [16] Encyklopedia Zarządzania. Dostępne pod adresem: <https://www.encyklopediazarzadzania.pl>
- [17] Mamczur, M. (2020). *Przykładowa sieć neuronowa MLP w Tensor-flow*. Dostępne pod adresem: <https://www.towardsdatascience.com/machine-learning-part-20-dropout-keras-layers-explained-8c9f6dc4c9ab>
- [18] Mamczur, M. (2021). *Jak działają konwolucyjne sieci neuronowe (CNN)?*. Dostępne pod adresem: <https://miroslawmamczur.pl>
- [19] Keras Documentation. *Adam Optimizer*. Dostępne pod adresem: <https://keras.io/api/optimizers/adam/>
- [20] The Data Game. (2024). *Warstwa Dropout w Sieciach Neuronowych*. Dostępne pod adresem: <https://www.towardsdatascience.com/machine-learning-part-20-dropout-keras-layers-explained-8c9f6dc4c9ab>